V-Die 单 MoE 层完整仿真报告

三模型 · 八组合完整消融 · 强 TDMA 对照 · 单因素敏感性

批准版本：VDIE-FULL-v1.0-review-1；用户确认日期：2026 年 11 月 5 日（Asia/Shanghai）。

全部 4,020 条计划记录完成；FP8 端到端数值误差验收未通过。experiments_complete=true，complete=false。

批准的 NRMSE 上限仍为 5%，未改阈值、未删除失败断言。该失败与时序/能耗描述符实验分开报告，不能宣称已满足规范的全部验收要求。

1. 仿真目标

测量 Base 上输入就绪至 Base 收到输出的单 MoE 层延迟与模型估计能耗，通过完整 2^3 消融分离动态 OFDMA、Dispatch 广播、Local Combine 及其交互作用；另与包粒度强 TDMA 比较。

层内计算、共享内存接口、无线控制/数据服务、半双工冲突、缓冲区背压、shared 专家和本地归并进入同一事件模型；不通过总字节除总带宽估算整层时间。

2. 仿真简述

数据路径为 Base 输入→owner Gate/Top-k→Dispatch→专家计算→可选 Local Combine→owner 最终 Combine→Base 输出。Python 组织配置、输入、统计、审计与报告，本地 C++扩展加速整数皮秒离散事件内核。计算/DMA 按 5ns 主时钟对齐，无线按 1ps 事件分辨率处理，跨帧保留分数 bit 服务。

文本来自 MohamedRashad/ChatGPT-prompts，使用三个模型冻结 revision 中的官方 tokenizer，不加特殊 token 或聊天模板。路由为受控合成，标记 dataset_tokens_synthetic_router；没有加载预训练模型权重或采集真实隐藏状态。Decode 重放回复 token，单层耗时不代表完整模型 TBT。

权重预驻留，计本层热态执行。Attention、KV cache、其它层、初始化权重装载、外部主存及 residual add 均不在计时边界内。M3 每 token 只计算两个 shared 分支，owner/buddy 各一个。

模型	隐藏/专家中间维度	routed / Top-k / shared	每 Die 驻留字节
M1	2880 / 2880	32 / 4 / 0	54,083,520
M2	2048 / 768	128 / 8 / 0	42,214,464
M3	2560 / 1536	64 / 6 / 2	63,355,280

两个能耗账本均含计算、向量处理、eDRAM 读写、刷新、泄漏、RF 及控制待机；baseband_stress 再加未标定的在线 EQ 和 OFDMA 额外基带 proxy。默认刷新约 3.02545W/Die、16Die 约 48.40727W，保持连续后台积分。这些是参数外推，不是目标芯片实测功耗。

3. 仿真参数表

下表包含全部 211 项原规范机器参数。取值、单位、含义与依据来自已批准规范，运行期未改变模型参数或 5%数值门槛；扫描值见 experiment 组。U/P/C/D/A 分别表示用户固定、论文记录、官方配置、设计选择、未验证外推。参数表 CSV 另保留逐项文献 URL，完整引用见附录。

spec

参数键	值	单位	含义与规则	依据
spec.version	"1.0"	—	本次执行规范版本；2026-11-04 核对文献	D

simulation

参数键	值	单位	含义与规则	依据
simulation.engine	"discrete_event"	—	Python 架构级离散事件仿真；不执行完整 LLM	D
simulation.time_unit_ps	1	ps	事件时间使用整数皮秒，避免浮点累积误差	D
simulation.seed_list	[20261104, 20261105, 20261106, 20261107, 20261108]	—	五组配对随机种子；相同 trace 用于所有 baseline	D
simulation.fp8_numeric_test_tokens	16	token	小尺寸数值校验的 token 数；性能仿真不实际做数十亿次乘加	D
simulation.numeric_test_d	64	element	小尺寸数值校验隐藏维度	D
simulation.numeric_test_h	32	element	小尺寸数值校验专家中间维度	D
simulation.fp32_rtol	1e-05	—	无链路量化时不同 Combine 顺序的相对误差容限	D
simulation.fp32_atol	1e-06	—	无链路量化时的绝对误差容限	D
simulation.fp8_nrmse_limit	0.05	—	受控随机小算例的 FP8 输出归一化误差阈值；不是模型精度保证	D
simulation.fp8_cosine_min	0.99	—	上述小算例的余弦相似度检查阈值	D

models.M1

参数键	值	单位	含义与规则	依据
models.M1.repo	"openai/gpt-oss-20b"	—	模型及其 tokenizer 的官方仓库	[P3] [C1] [C4]
models.M1.total_params_b	20.91	10^9 parameters	整模型参数量，仅说明规模；不乘入单层开销	[P3] [C1] [C4]
models.M1.active_params_b	3.61	10^9 parameters/token	整模型激活参数量；各论文统计口径不完全相同	[P3] [C1] [C4]
models.M1.d_model	2880	element	单层输入、输出 activation 长度	[P3] [C1] [C4]
models.M1.d_ff	2880	element	每个 routed expert 的中间维度	[P3] [C1] [C4]
models.M1.routed_experts	32	expert/layer	本层独立 routed expert 数量	[P3] [C1] [C4]
models.M1.top_k	4	expert/token	每 token 选择的不重复 routed expert 数量	[P3] [C1] [C4]
models.M1.shared_experts	0	expert/layer	每 token 必须计算的 shared expert 数；不占 top-k	[P3] [C1] [C4]
models.M1.shared_d_ff	0	element	每个逻辑 shared expert 的中间维度；M3 官方融合宽度为 3072	[P3] [C1] [C4]
models.M1.transformer_layers	24	layer	整模型层数，仅用于标识模型	[P3] [C1] [C4]
models.M1.moe_layers	24	layer	整模型 MoE 层数；本任务只计其中一层	[P3] [C1] [C4]
models.M1.layer_index	1	zero-based	统一选第 2 个 Transformer block 的 MoE；M3 第 1 个 block 是 dense	D；结构依据 [P3] [C1] [C4]
models.M1.expert_linear_bias	true	bool	M1 的 gate/up/down 含 bias；M2/M3 不含	[P3] [C1] [C4]
models.M1.router_linear_bias	true	bool	M1 router 线性映射有 bias	[P3] [C1] [C4]
models.M1.router_correction_fp32	false	bool	M3 的专家选择 correction bias；合成 trace 设零，真 trace 保留	[C5]；默认值 D
models.M1.activation	"gpt_oss_swiglu"	—	专家非线性；禁止把三种模型都改成同一激活	[P3] [C1] [C4]

参数键	值	单位	含义与规则	依据
models.M1.swiglu_alpha	1.702	—	GPT-oss 自定义 SwiGLU sigmoid 系数	[C4]
models.M1.swiglu_limit	7.0	—	GPT-oss gate 上限及 up 分支双侧限幅	[C1] [C4]
models.M1.expert_matrix_params	24883200	parameter	3*d_model*d_ff，三个矩阵的元素总数	派生：[P3] [C1] [C4]
models.M1.expert_params_including_bias	24891840	parameter	单个专家参数量，M1 加上三个线性 bias	派生：[P3] [C1] [C4]
models.M1.expert_storage_bytes	24898464	byte	FP8 矩阵/bias 加所有 FP32 block scales	派生：模型尺寸 + [P6] 的分块规则
models.M1.router_storage_bytes	92288	byte/die	完整 router 副本及其 scale/bias/correction 的容量	派生：模型配置与本规范量化格式
models.M1.resident_bytes_per_die	54083520	byte/die	专家 + router + 固定 4MiB 工作区；必须不超过 64,000,000	派生：本规范映射与容量核算

models.M2

参数键	值	单位	含义与规则	依据
models.M2.repo	"Qwen/Qwen3-30B-A3B"	—	模型及其 tokenizer 的官方仓库	[P4] [C2]
models.M2.total_params_b	30.5	10^9 parameters	整模型参数量，仅说明规模；不乘入单层开销	[P4] [C2]
models.M2.active_params_b	3.3	10^9 parameters/token	整模型激活参数量；各论文统计口径不完全相同	[P4] [C2]
models.M2.d_model	2048	element	单层输入、输出 activation 长度	[P4] [C2]
models.M2.d_ff	768	element	每个 routed expert 的中间维度	[P4] [C2]
models.M2.routed_experts	128	expert/layer	本层独立 routed expert 数量	[P4] [C2]

参数键	值	单位	含义与规则	依据
models.M2.top_k	8	expert/token	每 token 选择的不重复 routed expert 数量	[P4] [C2]
models.M2.shared_experts	0	expert/layer	每 token 必须计算的 shared expert 数；不占 top-k	[P4] [C2]
models.M2.shared_d_ff	0	element	每个逻辑 shared expert 的中间维度；M3 官方融合宽度为 3072	[P4] [C2]
models.M2.transformer_layers	48	layer	整模型层数，仅用于标识模型	[P4] [C2]
models.M2.moe_layers	48	layer	整模型 MoE 层数；本任务只计其中一层	[P4] [C2]
models.M2.layer_index	1	zero-based	统一选第 2 个 Transformer block 的 MoE；M3 第 1 个 block 是 dense	D；结构依据 [P4] [C2]
models.M2.expert_linear_bias	false	bool	M1 的 gate/up/down 含 bias；M2/M3 不含	[P4] [C2]
models.M2.router_linear_bias	false	bool	M1 router 线性映射有 bias	[P4] [C2]
models.M2.router_correction_fp32	false	bool	M3 的专家选择 correction bias；合成 trace 设零，真 trace 保留	[C5]；默认值 D
models.M2.activation	"silu_glu"	—	专家非线性；禁止把三种模型都改成同一激活	[P4] [C2]
models.M2.expert_matrix_params	4718592	parameter	3*d_model*d_ff，三个矩阵的元素总数	派生：[P4] [C2]
models.M2.expert_params_including_bias	4718592	parameter	单个专家参数量，M1 加上三个线性 bias	派生：[P4] [C2]
models.M2.expert_storage_bytes	4719744	byte	FP8 矩阵/bias 加所有 FP32 block scales	派生：模型尺寸 + [P6] 的分块规则
models.M2.router_storage_bytes	262208	byte/die	完整 router 副本及其 scale/bias/correction 的容量	派生：模型配置与本规范量化格式
models.M2.resident_bytes_per_die	42214464	byte/die	专家 + router + 固定 4MiB 工作区；必须不超过 64,000,000	派生：本规范映射与容量核算

models.M3

参数键	值	单位	含义与规则	依据
models.M3.repo	"baidu/ERNIE-4.5-21B-A3B-PT"	—	模型及其 tokenizer 的官方仓库	[P5] [C3] [C5]
models.M3.total_params_b	21.0	10^9 parameters	整模型参数量，仅说明规模；不乘入单层开销	[P5] [C3] [C5]
models.M3.active_params_b	3.0	10^9 parameters/token	整模型激活参数量；各论文统计口径不完全相同	[P5] [C3] [C5]
models.M3.d_model	2560	element	单层输入、输出 activation 长度	[P5] [C3] [C5]
models.M3.d_ff	1536	element	每个 routed expert 的中间维度	[P5] [C3] [C5]
models.M3.routed_experts	64	expert/layer	本层独立 routed expert 数量	[P5] [C3] [C5]
models.M3.top_k	6	expert/token	每 token 选择的不重复 routed expert 数量	[P5] [C3] [C5]
models.M3.shared_experts	2	expert/layer	每 token 必须计算的 shared expert 数；不占 top-k	[P5] [C3] [C5]
models.M3.shared_d_ff	1536	element	每个逻辑 shared expert 的中间维度；M3 官方融合宽度为 3072	[P5] [C3] [C5]
models.M3.transformer_layers	28	layer	整模型层数，仅用于标识模型	[P5] [C3] [C5]
models.M3.moe_layers	27	layer	整模型 MoE 层数；本任务只计其中一层	[P5] [C3] [C5]
models.M3.layer_index	1	zero-based	统一选第 2 个 Transformer block 的 MoE；M3 第 1 个 block 是 dense	D；结构依据 [P5] [C3] [C5]
models.M3.expert_linear_bias	false	bool	M1 的 gate/up/down 含 bias；M2/M3 不含	[P5] [C3] [C5]
models.M3.router_linear_bias	false	bool	M1 router 线性映射有 bias	[P5] [C3] [C5]
models.M3.router_correction_fp32	true	bool	M3 的专家选择 correction bias；合成 trace 设零，真 trace 保留	[C5]；默认值 D

参数键	值	单位	含义与规则	依据
models.M3.activation	"silu_glu"	—	专家非线性；禁止把三种模型都改成同一激活	[P5] [C3] [C5]
models.M3.expert_matrix_params	11796480	parameter	3*d_model*d_ff，三个矩阵的元素总数	派生：[P5] [C3] [C5]
models.M3.expert_params_including_bias	11796480	parameter	单个专家参数量，M1 加上三个线性 bias	派生：[P5] [C3] [C5]
models.M3.expert_storage_bytes	11799360	byte	FP8 矩阵/bias 加所有 FP32 block scales	派生：模型尺寸 + [P6] 的分块规则
models.M3.router_storage_bytes	164176	byte/die	完整 router 副本及其 scale/bias/correction 的容量	派生：模型配置与本规范量化格式
models.M3.resident_bytes_per_die	63355280	byte/die	专家 + router + 固定 4MiB 工作区；必须不超过 64,000,000	派生：本规范映射与容量核算

precision

参数键	值	单位	含义与规则	依据
precision.activation	"FP8_E4M3FN"	—	所有矩阵输入、层输入/输出、跨 Die activation/partial 的载荷类型	U；具体格式参考 [P6]
precision.weight	"FP8_E4M3FN"	—	专家与 router 权重、线性 bias 按 FP8 存储；M1 不沿用原 MXFP4	U；格式 [P6]；M1 原格式 [P3]
precision.accumulator	"FP32"	—	MAC 累加、softmax、路由概率、Combine 累加的内部精度	D，参考 [P6] 的高精度累加
precision.weight_block	[128, 128]	element	FP8 权重每个二维 block 共用一个 FP32 scale	[P6] §3.3.2；对本架构的采用为 D
precision.activation_block	128	element	activation 每 token 每 128 元素一个 scale	[P6] §3.3.2
precision.scale_bytes	4	byte	每个 scale 的 FP32 字节数	D
precision.fp8_max	448	—	E4M3FN 最大有限值；amax/448 决定 scale	E4M3FN 格式定义，采用 [P6]
precision.scale_zero_amax	1.0	—	全零块的 scale，避免除零	D
precision.rounding	"nearest_even_saturate"	—	最近偶数舍入、有限范围饱和；不得用 INT8 代替 FP8	D

hardware

参数键	值	单位	含义与规则	依据
hardware.vdies	16	die	Expert V-Die 数量	U
hardware.base_dies	1	die	Base Die 数量；只作为本层输入/输出端点	U/按系统描述
hardware.clock_hz	200000000	Hz	主数字时钟；一个周期 5ns，不是 THz 载频	U
hardware.peak_ops_s	1000000000000	OP/s/die	FP8 峰值 1TOPS；乘法和加法各计 1 OP	U；OP 口径 [P2] Table II
hardware.ops_per_mac	2	OP/MAC	一次乘加计两个操作，防止 2 倍算力错误	[P2] Table II 脚注
hardware.edram_bytes	64000000	byte/die	64MB 按十进制解释，比 64MiB 更保守；所有驻留内容合计受限	U；单位约定 D
hardware.workspace_bytes	4194304	byte/die	4MiB 工作区从上述 64MB 内扣除，不额外赠送容量	D
hardware.buffer_partition_bytes	[524288, 1048576, 1048576, 1048576, 524288]	byte	依次为权重 tile 双缓冲、RX、TX、activation/FP32 partial、控制描述符	D
hardware.tx_return_reserve_bytes	524288	byte/die	TX 缓冲中至少 512KiB 保留给 Return/Output，避免 Dispatch 堵塞完成路径	D
hardware.rx_return_reserve_bytes	524288	byte/die	RX 缓冲中至少 512KiB 保留给 Return，防止 Dispatch 占满接收空间	D
hardware.partial_owner_reserve_bytes	262144	byte/die	activation/partial 分区中 256KiB 保留给 owner 最终累加器，余下用于专家中间值	D
hardware.owner_inflight_limit	16	token/die	每 owner 最多保留 16 个未完成 token，超限在 Base 排队	D
hardware.vector_lanes	64	element-OP/cycle	Top-k、激活函数、scale、Combine 的向量处理宽度	D
hardware.compute_utilization	1.0	ratio	tile 内理想计算效率；边界用实际尺寸，不凭空填充全 tile	D；强制做敏感性检验
hardware.compute_setup_cycles	2	cycle/task	一项矩阵或向量任务的固定启动开销	D
hardware.compute_voltage_v	1.1	V	目标计算域工作电压，按 [P2] Fig.21 约 215MHz 点选择以覆盖 200MHz	[P2] Fig.21 图读近似 + D
hardware.edram_voltage_v	0.9	V	eDRAM 采用独立电压域；不是将两个论文工艺宣称为同一芯片	[P7] Table 1；集成为 A
hardware.temperature_c	27	degC	eDRAM 参数标定温度；不模拟热反馈	[P7] Table 1

compute

参数键	值	单位	含义与规则	依据
compute.tile_m	16	token	专家一次最多合并 16 个已到达 token	D
compute.tile_n	128	element	输出维度 tile 宽度	D，匹配 [P6] 分块
compute.tile_k	128	element	归约维度 tile 宽度	D，匹配 [P6] 分块
compute.batch_wait_cycles	20	cycle	最老 token 最多等 100ns 聚批；满 16 或上游窗口关闭可提前发射	D
compute.activation_ops_per_element	8	vector-OP	普通 SwiGLU 每中间元素的保守等效成本	A：非线性电路未提供，固定于全部 baseline
compute.gpt_activation_ops_per_element	12	vector-OP	含限幅与额外乘加的 GPT-oss SwiGLU 成本	A；函数依据 [C4]
compute.softmax_ops_per_element	8	vector-OP	softmax/归一化的等效标量成本	A
compute.quantize_ops_per_element	3	vector-OP	amax、缩放、转换的等效成本；scale 决策按 128 元素组	A
compute.vector_energy_multiplier	4.0	ratio	FP32 向量操作相对 FP8 等效 OP 的能耗倍率	A；必须随能耗系数一起检验
compute.energy_scale	1.0	ratio	FP16 原型迁移到 FP8 的额外修正默认不赠送降耗	A；1 表示不作位宽线性减半
compute.extra_idle_power_w	0.01	W/die	计算/控制域额外待机功耗，独立于 eDRAM 与 RF	A；[P2] 未给本目标 Die 待机功耗
compute.base_io_idle_power_w	0.01	W	只计 Base 在本层边界内的 I/O 控制待机	A；不计 Base 的 Attention 等计算

memory

参数键	值	单位	含义与规则	依据
memory.banks	64	bank/die	eDRAM 逻辑 bank 数	D

参数键	值	单位	含义与规则	依据
memory.external_bytes_per_bank_cycle	16	byte/cycle	每 bank 对计算/DMA 可提供 128bit，读写共享额度	D
memory.bandwidth_scale	1.0	ratio	有效用户端口吞吐相对 64bank×16B/cycle 的倍率；固定访问时延不缩放	D；敏感性取 0.5/1/2
memory.access_latency_cycles	1	cycle	最小访问时延 5ns；文献 2ns 访问能力向 200MHz 周期取整	[P7] §3；向目标时钟换算 D
memory.read_pj_bit	0.025	pJ/bit	小宏 read 能量，25fJ/bit；非 64MB 成品实测	[P7] §3，电路仿真；容量扩展 A
memory.write_pj_bit	0.04	pJ/bit	小宏 write 能量，40fJ/bit	[P7] §3，电路仿真；容量扩展 A
memory.refresh_pj_bit	0.065	pJ/bit/refresh	一次完整 read+write refresh，65fJ/bit	[P7] §3
memory.refresh_period_ps	11000000	ps	11us 的标称保持/刷新周期；6us 作为保守敏感性点	[P7] Table 1；最坏条件见 §3
memory.leakage_pw_bit	1.25	pW/bit	按 Table 1 取泄漏，正文另一工作条件为 0.93；不得混用	[P7] Table 1
memory.refresh_blocks_user_port	false	bool	为 refresh 保留内部端口，用户端口不被阻塞；仍全额计刷新能量	[P7] internal-refresh 模式；大容量集成 A
memory.refresh_scope	"entire_capacity"	—	每个已启用 Die 的全部 64MB 保持数据；不靠 baseline 改刷新范围	D，保守配置
memory.energy_scale	1.0	ratio	小宏扩展到 64MB 的 read/write/refresh 能量修正；不改变单列的 bitcell 泄漏，主值 1 为乐观 proxy	A；强制检验 1/2/4

mapping

参数键	值	单位	含义与规则	依据
mapping.routed	"expert_id_mod_16"	—	routed expert e 放在 e mod 16；不复制、不切分	D
mapping.owner	"request_ordinal_mod_16"	—	一个请求的所有 token 固定 owner=req_ordinal mod 16	D
mapping.shared	"parity_replica_pair"	—	M3：S0 在偶数 Die、S1 在奇数 Die 各 8 份；token 只用 owner 和 owner xor 1 两份	D；原 shared 宽度依据 [C3] [C5]
mapping.router_replicas	16	copy	每 Die 有完整且相同的 router；每 token 仅 owner 执行一次 Gate	D，符合用户数据流
mapping.warm_weights	true	bool	单层全部权重预驻留；不计启动装载，不发生层间换权重	D，任务只比较一层热态输入到输出

radio

参数键	值	单位	含义与规则	依据
radio.groups_per_vdie	2	group/die	Base 通信组与 peer 通信组各一组	U
radio.channels_per_group	1	channel/group	每组按论文 1 的一条物理通道计，不把双通道 264Gb/s 给每组	D；[P1] 通道定义
radio.base_groups	1	group	Base 有一条聚合接入信道；不是 16 条独立满带宽链路	D，避免扩张 Base 带宽
radio.carrier_hz	153800000000	Hz	实测锁定本振频率 153.8GHz，约 0.154THz	[P1] §V / Fig.21
radio.reference_bandwidth_hz	45000000000	Hz	5 层/50um 模拟链路约 45GHz 带宽，仅作频谱约束背景，不拿载频算速率	[P1] §II-B，EM 仿真
radio.ptp_raw_bps	132000000000	bit/s/channel	有离线 EQ 的单通道点对点峰值	[P1] §V / Fig.25–26 / Table II
radio.broadcast_raw_bps	80000000000	bit/s/channel	较长路径广播实测 80Gb/s；主实验不使用更乐观 124Gb/s	[P1] §V / Fig.27(b)，after EQ
radio.rate_scale	1.0	ratio	16 节点覆盖、耦合/干扰与新 PHY 带来的未知降额；全部方法一起缩放	A；[P1] 未验证 16 节点全互连
radio.half_duplex_per_group	true	bool	同组同一时刻 TX 或 RX；不同组可并发，不能将同组当全双工	D，符合 [P1] TX/RX/OFF 切换
radio.spatial_reuse	false	bool	同一介质内不重用相同 RU；16 节点共享总频谱预算	D，保守互扰模型
radio.independent_groups	true	bool	Base 介质与 peer 介质可并行，二者硬件参数相同	U；两组足够隔离是 A
radio.rx_pipeline_cycles	2	cycle	完整包接收后的数字处理延迟 10ns	A
radio.propagation_delay_ps	20	ps	短距离传播延迟，仅架构占位，非 16-Die 实测	A
radio.residual_packet_error	0.0	probability	主实验假设可靠服务；不从两/四层 BER 外推 16 节点 BER	A；不做物理链路可靠性结论
radio.multicast_receivers	"destination_mask"	—	控制时段所有节点监听；载荷仅目的 Die 启用接收前端	D；需对 all_non_source 接收方式做敏感性检验

mac

参数键	值	单位	含义与规则	依据
mac.frame_cycles	20	cycle	TDMA/OFDMA 统一 100ns 调度帧，全部基线一致	D
mac.control_cycles	4	cycle/frame	20ns 控制预算下限；降额时按报告/grant 字节延长，并从数据窗口扣除	A
mac.guard_cycles	1	cycle/frame	5ns 保护/方向切换，从数据窗口扣除	A
mac.queue_report_bytes	8	byte/node/frame	每节点每组只报告一个最高优先级 HOL 候选的 mask、bytes、age/type 和 credit	D
mac.grant_header_bytes	8	byte/frame	调度 grant 固定头，包含帧号/状态及 CRC	D
mac.grant_bytes_per_ru	4	byte/RU	每 RU 发送者/目的 mask/方向映射，T 模式仍发同长度 grant	D
mac.arbitration_cycles	1	cycle/frame	控制报告结束到 grant 的数字仲裁预算；作为固定并行硬件假设	A
mac.peer_arbiter_die	0	die_id	peer 介质由 Die0 仲裁；base 介质由 Base 仲裁，控制通信和固定仲裁延迟显式计费	D
mac.fft_size	256	bin	OFDMA 服务模型的归一化子载波格点数；不是已有 THz 芯片参数	D
mac.data_subcarriers	224	bin	载荷格点，其余用于 pilot/guard	D
mac.pilot_subcarriers	16	bin	归一化导频开销	D
mac.guard_subcarriers	16	bin	归一化频域保护开销	D
mac.cp_samples	16	sample	归一化循环前缀开销；额外效率=224/(256+16)	D
mac.resource_units	16	RU	每 RU 含 14 个数据格点；按帧动态分配，绝不每个 RU 都给 132Gb/s	D
mac.starvation_limit_frames	16	frame	等待达到 16 帧的 flow 优先，保证有限队列无饥饿	D
mac.packet_header_bytes	32	byte/packet	固定网络头，含 token UID/owner/消息类型/目的 mask/分片信息	D
mac.crc_bytes	4	byte/packet	CRC32 开销；虽然主实验不注入误码仍计字节	D

参数键	值	单位	含义与规则	依据
mac.dispatch_entry_bytes	8	byte/expert	expert_id 2B + gate weight FP32 4B + flags 2B	D
mac.mtu_payload_bytes	4096	byte/packet	最大 body，超长分片每片重计 header/CRC；不计虚假 padding token	D

energy

参数键	值	单位	含义与规则	依据
energy.lo_w_per_node	0.032	W/node	一个共享 VCO 覆盖本 Die 两组；热态测试全程保持锁定	[P1] §III-B 为 32mW 电路仿真；两组共享采用 D
energy.tx_increment_w_per_group	0.00635	W/active group	(44.7mW−32mW)/2；从 L4 TX 双通道模块分解	[P1] §V + 仿真 LO 功耗，分解值为 A/派生
energy.rx_increment_w_per_group	0.0056	W/active group	(43.2mW−32mW)/2；从 L3 RX 双通道模块分解	[P1] §V + 仿真 LO 功耗，分解值为 A/派生
energy.equalizer_extra_w_per_rx	0.02	W/active RX group	补偿论文 1 未集成的在线均衡功耗；不能标为实测	A；另检验 0/20/100mW
energy.ofdma_extra_w_per_active_group	0.40896428571428567	W	完整基带成本压力情景：347mW*(132/112)；不是已测 THz OFDMA 增量	[P8] RX 参照 + 速率线性外推 A；TX 同值为 A
energy.report_modes	["frontend_proxy", "baseband_stress"]	—	必须同时输出：不含未标定 EQ/OFDMA 基带的能量；加入上述压力 proxy 的能量	D，不能把任一值称为实测整机能耗
energy.compute_pj_op	0.06980500749971157	pJ/OP	21.4TFLOPS/W @0.9V 按 V^2 外推 1.1V；FP8 修正默认 1	[P2] Table III + 动态能量 V^2 近似 A

workload

参数键	值	单位	含义与规则	依据
workload.dataset	"MohamedRashad/ChatGPT-prompts"	—	HybriMoE 引用的 ChatGPT Prompts，不是 awesome-chatgpt-prompts	[P9] § VI-A5/参考文献 30；[D1]
workload.split	"train"	—	官方数据划分；本次页面列 360 行，执行时记录实际版本行数	[D1]
workload.prompt_column	"human_prompt"	—	Prefill 输入文本列	[D1]
workload.response_column	"chatgpt_response"	—	Decode 教师强制重放文本列，不宣称本模型生成	[D1]
workload.requests_per_seed	128	request	清洗后无放回采样 128 个请求；不足时失败，不偷偷复用	D
workload.prefill_batches	[1, 8, 32]	request/batch	原生 prompt 长度，每批独立释放并排空	D；区分 prefill/decode 参考 [P9]
workload.prefill_length_cap	1024	token/request	仅截断长 prompt，不补齐短 prompt	D；[P9]也报告至 1024 token 的 prefill 工作负载
workload.decode_batches	[1, 8, 32, 128]	request/batch	每活跃请求每轮只产生一个 MoE 输入 token	D
workload.decode_steps_cap	64	step/request	最多重放回复前 64 个 token，短回复自然结束	D
workload.decode_refill	false	bool	同一 cohort 不回填请求，结束时报告真实有效 B 的变化	D
workload.arrival	"closed_cohort_barrier"	—	Prefill 批内 t=0 可用；Decode 下一轮等本轮全部输出返回再释放	D，阻止将完整 response 一次当 decode 输入
workload.tokenization	"official_plain_text_no_special_tokens"	—	每模型用官方 tokenizer；编码原字段，不加入聊天模板	D，固定长度口径
workload.input_trace_mode	"dataset_tokens_synthetic_router"	—	真实数据集 token/长度 + 受控合成路由；不伪称真实隐藏状态/真实专家命中	D，CPU 默认可完整执行
workload.routing_profile	"uniform"	—	主结果：所有专家可交换，无人为热点以保证无偏基线	D
workload.zipf_alpha	1.2	—	热点敏感性：先随机置换 expert 排名，再按 r^(-1.2)生成偏置	D；不是论文测得的特定模型分布
workload.decode_reuse_probability	0.0	probability	主结果不强加跨 token 相关性；敏感性另取 0.8	D

参数键	值	单位	含义与规则	依据
workload.source_revision	"resolve_and_freeze"	—	首次读取冻结 dataset/tokenizer commit 及 SHA256；后续全部离线复用	D，禁止随机跟随 main 变化

experiment

参数键	值	单位	含义与规则	依据
experiment.baseline_ids	["T_P_N", "T_B_N", "T_P_L", "T_B_L", "O_P_N", "O_B_N", "O_P_L", "O_B_L"]	—	T=单载波 TDMA，O=动态 OFDMA，P=逐目的 Die 点对点，B=广播，N/L=无/有 Local Combine	U；采用完整 2^3 消融 D
experiment.strong_tdma_ids	["TW_P_N", "TW_B_L"]	—	无固定帧空尾的包粒度 work-conserving TDMA 压力对照	D，防止优势仅来自弱 TDMA 实现
experiment.sensitivity_cases	["prefill_B32", "decode_B32"]	—	敏感性与强 TDMA 用两个代表负载；三模型、五种子全部运行	D
experiment.sensitivity_baseline_ids	["T_P_N", "O_P_N", "T_B_L", "O_B_L"]	—	敏感性保留两组可比的 T/O 配对；完整三因素消融由主实验八组合承担	D
experiment.rate_scale_values	[0.25, 0.5, 1.0]	ratio	16 节点覆盖和新 PHY 的速率降额	A
experiment.broadcast_rate_values	[80000000000, 124000000000]	bit/s	实测较长/较短广播路径的两个标定点	[P1] Fig.27
experiment.compute_utilization_values	[0.5, 0.75, 1.0]	ratio	不改变 1TOPS 峰值的有效计算利用率敏感性	D
experiment.memory_bandwidth_scale_values	[0.5, 1.0, 2.0]	ratio	改变内部 bank/DMA 有效吞吐，暴露存储瓶颈	D
experiment.memory_energy_scale_values	[1.0, 2.0, 4.0]	ratio	eDRAM 小宏到大容量的能量外推敏感性	A
experiment.refresh_period_values_ps	[6000000, 11000000, 100000000]	ps	6/11us 来自[P7]不同条件；100us 来自[P10]另一 2T 设计，只是替代器件情景	[P7] [P10]；跨设计采用 A
experiment.compute_energy_scale_values	[0.5, 1.0, 2.0]	ratio	检验 FP16 到 FP8、工作电压与电路映射的不确定性	A

参数键	值	单位	含义与规则	依据
experiment.ofdma_extra_power_values_w	[0.0, 0.1, 0.40896428571428567]	W/group	理想下界、中间情景、[P8]速率归一化压力 proxy	D/A；高点依据 [P8]
experiment.equalizer_power_values_w	[0.0, 0.02, 0.1]	W/RX group	在线 EQ 未实测，检验共同开销	A
experiment.frame_cycles_values	[10, 20, 80]	cycle	50/100/400ns 请求调度粒度；实际帧长由控制报告/grant/仲裁预算和 guard 共同约束	D
experiment.multicast_rx_values	["destination_mask", "all_non_source"]	—	只目标接收与全体监听载荷的能量差异	A
experiment.routing_profiles	["uniform", "zipf"]	—	均匀与热点情景，必须分图报告	D
experiment.decode_reuse_values	[0.0, 0.8]	probability	Decode 跨步专家集合相关性的受控敏感性	D
experiment.idle_power_values_w	[0.0, 0.01, 0.05]	W/die	未测待机项敏感性，Base 控制项同步采用同值	A
experiment.bootstrap_resamples	1000	resample	对配对请求/cohort 统计作 bootstrap，输出 95%区间	D
experiment.confidence	0.95	probability	均值/节能率/加速比的置信区间水平	D
experiment.no_cartesian_sensitivity	true	bool	每次只改变一项；基线点去重，不跑所有敏感性参数笛卡尔积	D

已批准补充与执行约定

FP32 向量能耗倍率增加 2/4/8 单因素扫描（默认 4）；all_non_source 广播将所有非源节点纳入实际 RX 半双工冲突约束，重跑时序。Prefill 的 Decode 复用概率 0.8 记录为语义不适用的等价控制，明确引用默认轨迹。

约定键	执行值	单位	含义	依据
review.approval_id	VDIE-FULL-v1.0-review-1	—	本次参数审批版本；用户已确认批准。	D：本次审阅标识
review.simulation_allowed	true（用户已确认）	bool	仅用户明确通过本参数版本后才可运行数值仿真、性能仿真与正式实验。	用户本轮要求

约定键	执行值	单位	含义	依据
review.extra_vector_energy_values	[2.0, 4.0, 8.0]	ratio	补齐附件要求的 FP32 向量能耗倍率敏感性；默认 4，新增 2/8，各自单因素扫描，额外 240 条。附件未给此轴范围，此范围已随参数表获批准。	D/A：新增已批准范围
review.all_non_source_semantics	physical_receive_half_duplex	—	广播时所有非源 Die 实际开启 RX，并加入该组半双工冲突检查；逻辑贡献仍只交给目的 mask。重跑时序。避免把同时 TX 的节点虚构成可 RX；这是对附件能耗敏感性与半双工规则的明确化。	D：已批准实现口径
review.prefill_reuse_semantics	explicit_no_effect_control	—	复用概率仅作用于 Decode。保留 60 条 Prefill p=0.8 记录，明确引用相同默认时序/账本；标注不适用/等价复用，不算新仿真。	D：附件适用范围
runtime.python	3.12.14	version	沿用当前已发布环境的 CPython；额外依赖将在实现时固定版本并记入 manifest。	当前环境观测
runtime.max_processes	4	process	当前 4 CPU 配额、32GiB 内存；按独立运行配置并行，内存不足可减小进程数；不改变任何模型参数。	当前环境资源
data.empty_rule	strip_only_for_empty_check	—	空白字符串视为空；用于分词的原始文本不 strip、不改写。	D：清洗细化
data.duplicate_rule	exact_original_prompt_first_row	—	human_prompt 原字符串完全相同才去重，保留原行序首次出现的行。	附件第 4 节
data.row_id	zero_based_original_csv_row	—	row_id 在清洗前确定；跨模型保留同一抽样 ID 及顺序。	D：可复现标识
random.generator	numpy.PCG64	—	无放回抽样、路由和统计使用明确 PRNG，不使用 Python 随机化 hash。	D：补全未指定实现
random.request_sampling	PCG64(seed).choice(clean_rows,128,replace=False)	—	抽样结果的顺序就是 request_ordinal；同种子三个模型共用。	D：附件采样规则
random.seed_encoding	SHA256(UTF8(compact_JSON_tuple)) -> unsigned_big_endian_integer	—	路由 tuple 为[seed,model_id,row_id,mode,token_position]；哈希整数输入 PCG64。	D：附件 SHA256 规则细化
random.rank_domain	[seed,model_id,"expert_rank"]	—	Zipf 排名随机置换使用独立子流；不按 Die 人为堆积热点。	D：附件热点规则
random.reuse_domain	[seed,model_id,row_id,"decode_reuse",token_position]	—	Decode 复用决策独立于新抽样；第 0 步总是新采样，后续复用整个集合和权重。	D：附件复用规则
random.uniform_support	0<U<1; redraw_exact_zero	—	Gumbel 生成避免 log(0)；相同 logit 时按 expert_id 确定顺序。	D：数值规则
numeric.test_seed	20261104	—	小尺寸数值验证固定种子；activation 标准正态、权重标准差 1/sqrt(d)。	D：附件分布与固定种子
numeric.bias_rule	M1_zero_bias_fixture_plus_nonzero_bias_fixture	—	M1 既验证零 bias 也验证非零 bias（标准差 1/sqrt(d)的正态），M2/M3 不添加线性 bias。	D：检验 bias 实现

约定键	执行值	单位	含义	依据
numeric.nrmse_denominator_floor	1e-12	—	NRMSE=norm(y-y_ref)/max(norm(y_ref),1e-12)；余弦用展平输出。	附件第 5.2 节
numeric.reference	same_small_FP32_weights_and_inputs	—	逐模型激活函数与 shared 结构一致；FP8 误差含已定义量化，不宣称真实模型精度。	附件第 5.2/9 节
timing.digital_alignment_ps	5000	ps	计算/DMA 启动向上对齐 5ns；无线完成向上取整到 1ps，不提前交付。	派生：200MHz
timing.radio_service_remainder	exact_rational_bits_across_frames	—	跨帧保留分数 bit 服务量；仅到完整包并完成 RX pipeline 后消费。	附件第 6 节
timing.simultaneous_event_order	completion_release_then_ready_then_admission	—	同一时刻先完成与释放 credit，再产生依赖任务，最后调度；相同类用 token_uid/expert_id 等稳定键排序。	D：确定性实现
compute.task_priority	Combine > Gate > oldest_expert; tile_boundaries	—	只在 tile 或向量任务边界切换；所有任务共用 Die 的 1TOPS 资源。	附件第 5.3 节
compute.tile_loop	output_N_then_reduction_K	—	tile 最多 16×128×128；两个有界缓冲，每次调用复用该批 token 的权重读取。	附件第 5.3 节
memory.dma_service_policy	ready_time_fifo_then_stable_id_nonpreemptive_burst	—	每 Die 一个总额度共享接口；计算 tile、网络 RX/TX 实际按 burst 竞争；刷新有独立内部端口。	D：细化共享接口调度
memory.tile_buffers_bytes	[262144, 262144]	byte	512KiB 权重 tile 区等分双缓冲，合计不超既定 4MiB 工作区。	D：细化双缓冲分区
memory.input_uses_dispatch_partition	True	bool	Base INPUT 与 DISPATCH 使用非 Return 的 RX 额度；OUTPUT 与 RETURN 使用完成路径额度。	D：完成路径保护
memory.owner_accumulator_bytes	4*d_model*active_owner_tokens	byte	owner 保留 FP32 最终累加器，限 16 个 inflight；贡献到达累计后及时释放。	附件第 5.3 节
energy.enabled_vdies	16	die	整个 cohort 窗口全部 16 个 Die 的 64MB 刷新与泄漏均计入，不按路由命中关掉容量。	附件第 7 节
energy.locked_lo_nodes	17	node	Base 加 16Die，全窗口预锁定；每 Die 两组并发仍只计一次 LO。	附件第 7 节
energy.refresh_integration	continuous_average_over_cohort_makespan	—	按错相后台平均功耗积分；短于刷新周期也收费，不阻塞用户 DMA。	附件第 7 节
energy.control_frontends	base:1TX+16RX; peer:1TX+15RX	group	整个控制窗口（含仲裁和取整余量）保守唤醒；控制不计 OFDMA 额外基带。	附件第 7 节
statistics.bootstrap_unit	paired_seed_then_cohort_hierarchical	—	先有放回抽 5 个种子，再在种子内成组抽 cohort；所有 baseline 共用重抽索引；保留请求/token 相关性。	D：统计实现细化
statistics.bootstrap_rng	SHA256([20261104,"bootstrap",model,mode,B,axis,value])	—	1000 次配对分层 bootstrap；结果取 2.5%/97.5%分位，重复可复现。	D：统计实现细化

约定键	执行值	单位	含义	依据
statistics.ratio_estimator	ratio_of_paired_aggregate_means	—	加速比为成对均值延迟之比；节能率为 1 减成对均值能量比；不混用平均比值；同时保存逐 cohort 原始比值。	D：比较口径
statistics.percentiles	p50,p95; linear empirical interpolation	—	延迟分别按 token、请求、cohort/Decode 轮报告；不将跨 Die busy-time 求和冒充延迟。	附件第 7.2 节及 D
statistics.energy_per_token	sum_cohort_energy / actual_completed_tokens	—	公共待机能量只累计一次；不按 padding 或配置最大 token 数稀释能耗。	附件第 7.2 节
output.complete_rule	all_planned_records_resolved_and_all_acceptance_checks_passed	—	失败、未运行、能耗重算及等价复用分别标记；不把生成实验清单视为仿真完成。	附件第 9 节
output.final_report	results/simulation_report.docx	path	审批后完成仿真再生成最终 Word：目标、简述、参数表、流程、结果、整理与对照、结论。	用户本轮要求

派生量复算

派生项	数值	单位	含义	公式
clock_period	5	ns	200MHz 数字主时钟周期	1e9 / hardware.clock_hz
matrix_ops_per_cycle	5000	OP/cycle	每 Die 矩阵总资源额度	1e12 / 2e8
matrix_macs_per_cycle	2500	MAC/cycle	按 2OP/MAC 换算	5000 / 2
memory_user_bandwidth	204.8	GB/s/die	默认共享读写/DMA 额度（十进制 GB）	64 * 16 * 2e8 / 1e9
buffer_partition_sum	4194304	byte	工作区分区合计，不额外赠送	512KiB+1MiB+1MiB+1MiB+512KiB
M1.capacity_margin	9916480	byte/die	扣除专家/router/4MiB 工作区后余量	64,000,000 - resident_bytes_per_die
M1.vector_payload	2972	byte	含 FP32 scales 的一份 FP8 activation/partial	S(d)=d+4*ceil(d/128)
M1.contributors_bitmap	4	byte	返回包贡献集合位图	ceil((routed_experts+shared_experts)/8)
M1.expert_ops_per_token	49766400	OP	单个 routed expert 三矩阵算量；不含向量操作	6*d_model*d_ff
M1.gate_ops_per_token	184320	OP	owner 执行一次 router 矩阵映射	2*d_model*routed_experts

派生项	数值	单位	含义	公式
M1.owner_accumulator_max	184320	byte/die	16 个 inflight 时 owner FP32 最终累加器总量	4*d_model*16
M2.capacity_margin	21785536	byte/die	扣除专家/router/4MiB 工作区后余量	64,000,000 - resident_bytes_per_die
M2.vector_payload	2112	byte	含 FP32 scales 的一份 FP8 activation/partial	S(d)=d+4*ceil(d/128)
M2.contributors_bitmap	16	byte	返回包贡献集合位图	ceil((routed_experts+shared_experts)/8)
M2.expert_ops_per_token	9437184	OP	单个 routed expert 三矩阵算量；不含向量操作	6*d_model*d_ff
M2.gate_ops_per_token	524288	OP	owner 执行一次 router 矩阵映射	2*d_model*routed_experts
M2.owner_accumulator_max	131072	byte/die	16 个 inflight 时 owner FP32 最终累加器总量	4*d_model*16
M3.capacity_margin	644720	byte/die	扣除专家/router/4MiB 工作区后余量	64,000,000 - resident_bytes_per_die
M3.vector_payload	2640	byte	含 FP32 scales 的一份 FP8 activation/partial	S(d)=d+4*ceil(d/128)
M3.contributors_bitmap	9	byte	返回包贡献集合位图	ceil((routed_experts+shared_experts)/8)
M3.expert_ops_per_token	23592960	OP	单个 routed expert 三矩阵算量；不含向量操作	6*d_model*d_ff
M3.gate_ops_per_token	327680	OP	owner 执行一次 router 矩阵映射	2*d_model*routed_experts
M3.owner_accumulator_max	163840	byte/die	16 个 inflight 时 owner FP32 最终累加器总量	4*d_model*16
ofdma_efficiency	14/17 = 0.8235294117647058	ratio	数据子载波与 CP 只乘一次	224/(256+16)
fullband_unicast_ofdma	108.70588235294117	Gb/s	仅扣 OFDMA 效率，尚未扣 control/guard/包头	132 * 14/17
fullband_broadcast_ofdma	65.88235294117646	Gb/s	多目的广播满带宽数据窗口速率	80 * 14/17
base.control	25	ns/frame	报告、grant、仲裁取整后的控制窗口	max(20ns,ceil_5ns(8*N*8/132e9 + 8*72/80e9 + 5ns))
base.data_window	70	ns/frame	默认 100ns 帧内可用数据窗口	100ns - control - 5ns_guard
peer.control	20	ns/frame	报告、grant、仲裁取整后的控制窗口	max(20ns,ceil_5ns(8*N*8/132e9 + 8*72/80e9 + 5ns))
peer.data_window	75	ns/frame	默认 100ns 帧内可用数据窗口	100ns - control - 5ns_guard
compute_energy_anchor	0.06980500749971157	pJ/OP	FP16 原型能效及电压平方外推的 FP8 proxy	(1/21.4)*(1.1/0.9)^2
refresh_power_per_die	3.0254545454545454	W/die	全 64MB 连续后台刷新；为估计值	64e6*8*0.065e-12/11e-6
refresh_power_all_vdies	48.407272727272726	W	16Die 刷新功耗合计；不是仿真结果	16*refresh_power_per_die

派生项	数值	单位	含义	公式
memory_leak_per_die	0.0006399999999999999	W/die	仅 bitcell 泄漏，外围另外计费	64e6*8*1.25e-12
lo_power_system	0.544	W	17 节点热态 LO 全程功耗	17*0.032
control_idle_system	0.17	W	16Die 加 Base 的默认额外待机	16*0.01 + 0.01
ofdma_baseband_stress	0.40896428571428567	W/active group	DMT 整条 RX 速率外推的压力 proxy；TX 采用对称假设	0.347*132/112

4. 仿真流程

首先核对容量和算量，冻结数据集/tokenizer 及文件哈希，按五个种子无放回抽样 128 请求；同种子三个模型使用相同行 ID，各基线共用同一输入/路由 trace。

Prefill 按 B=1/8/32 分 cohort，不补齐短 prompt；Decode 按 B=1/8/32/128，每轮每活跃请求仅释放一个 token，等全部本轮输出到 Base 后进入下一轮，不回填请求。owner 最多 16 个 inflight token，超限在 Base 等待。

每个 Die 共用计算资源和 FIFO 内存接口。矩阵采用 M≤16、N/K≤128 的 tile 及两块有界预取缓冲；向量激活/量化按 128 元素 scale 块流式处理。Combine、Gate、expert 按优先级在任务/tile 边界调度，DMA 与无线存储操作竞争。返回和 owner 累加器空间先预留。

base/peer 分别共享一份频谱；同组半双工，不同组可重叠。T 逐帧独占一条 flow；O 先每条相容 flow 授 1RU，再按剩余需求分配；TW 收实际控制与 guard 后按包长服务。所有方案均计包头、CRC、MTU 分片、控制报告和 grant。

scheduler_metrics.csv 逐配置记录实际控制窗口、T/O 有效帧长、TW 平均 grant 服务时长以及控制占用。控制空口利用率以报告/grant 串行时间除以控制窗口；调度控制占比以控制时间除以已分配帧或 grant 时长。该调度分母包含已预留帧尾，不等同于 cohort 实测持续时间；TW 没有固定帧长，相关列留空。

部分	记录数	执行方式
主实验	840	三模型×八组合×七负载×五种子
强 TDMA	60	三模型×两策略×两代表负载×五种子
原规范敏感性	2880	14 轴；单因素；去重默认点
补充向量能耗敏感性	240	2/8 替代默认 4；只重算能量
合计	4020	2,280 时序 + 1,680 能耗重算 + 60 等价控制

先执行结构/边界检查和独立 FP8 校验，再完成全部清单。每个时序配置额外复算通信字节与矩阵 OP，验证 token、资源和依赖路径闭合。能耗情景从保存的事件计数重算；已有结果须通过配置、引擎与文件哈希校验才允许续跑。

统计以种子和 cohort 分层配对 bootstrap，重抽 1000 次，使用 95%区间。速度比是成对均值之比，节能率为 1 减成对总能量比；公共待机先按 cohort 累计，再除实际完成 token。资源 busy-time 可以重叠，不与依赖路径总延迟混用。

RU 诊断提供两种分母：data_window 是存在 grant 的完整数据窗口，含最后一帧剩余空尾；cohort_window 是两介质×16RU×实际 cohort 持续时间。前者描述已调度窗口内利用率，后者描述整个测量区间内利用率。空闲介质没有凭空占用射频数据活动功率。

5. 仿真结果

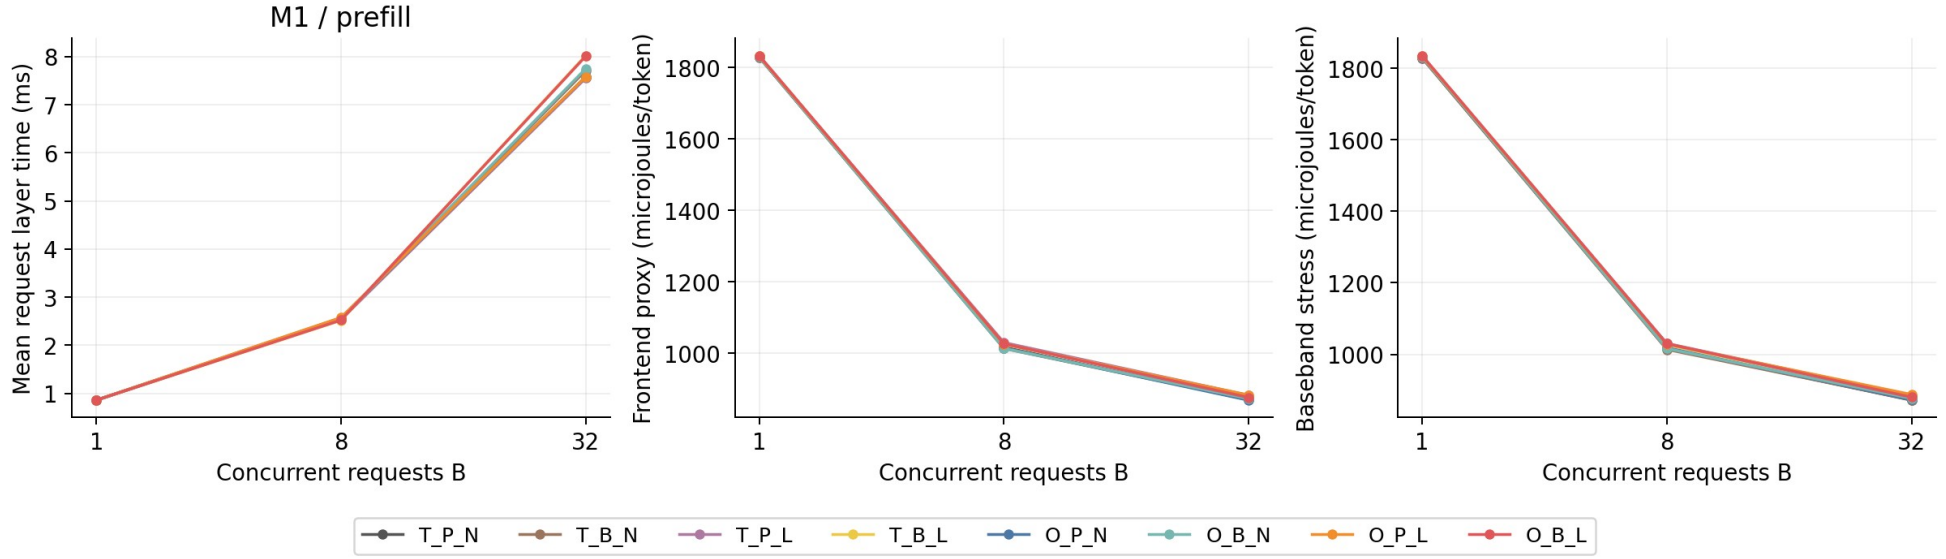
检查	实际结果
计划记录	4,020 / 4,020 已解决；各项状态保存在 manifest
结构与流程测试	191 项；失败 0、错误 0、跳过 0
FP8 门槛测试	8 项；失败 8、错误 0；原 NRMSE 门槛 0.05
配置级审计	每个时序配置均检查字节、矩阵 OP、token 与资源守恒、依赖路径闭合
完成状态	experiments_complete=True；complete=False

独立 ml_dtypes 0.5.3 对照已核对 1,000,506 个 E4M3FN 编码及全部 256 个解码码字，编码逐位一致。无量化的 FP32 Combine 等价性通过；完整 FP8 量化链的 NRMSE 仍超过批准上限，说明这一误差门槛没有被当前指定小算例满足。

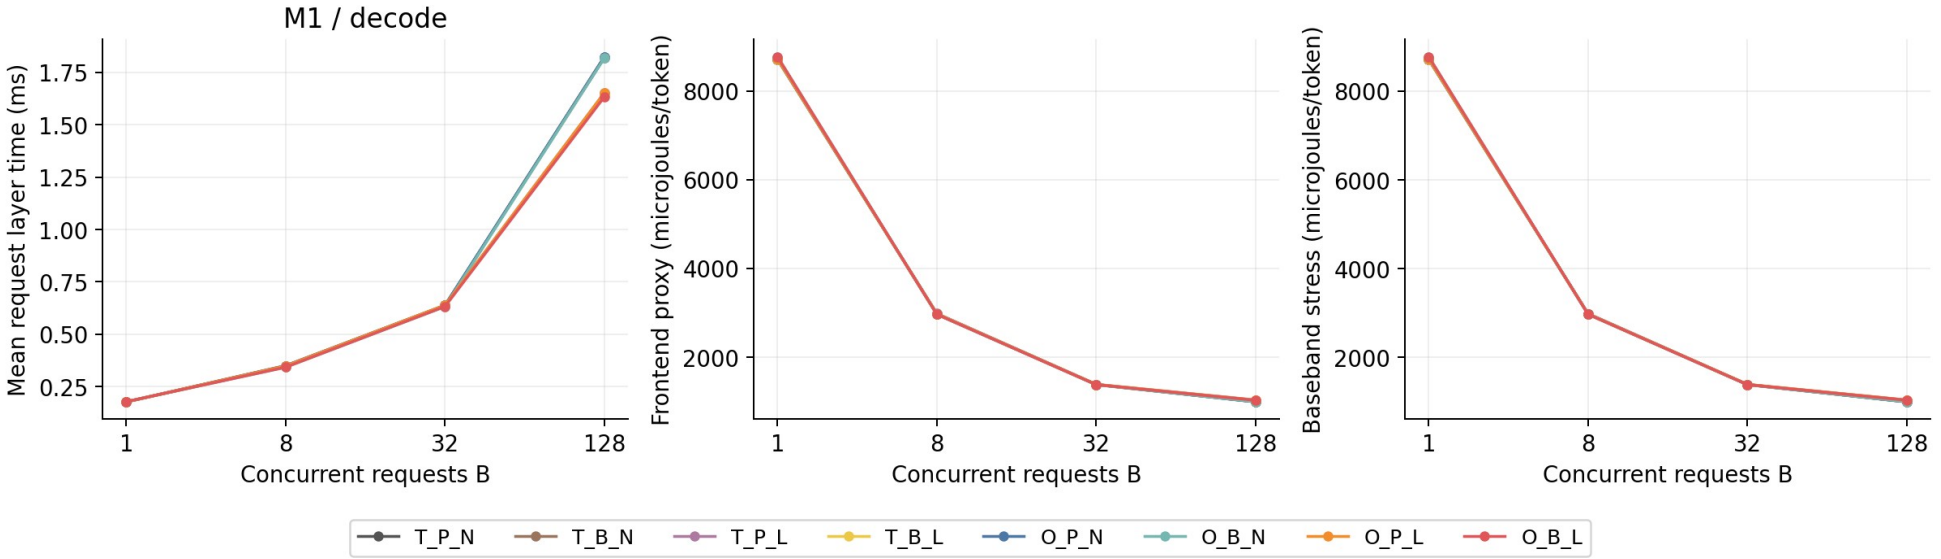
模型	M1 非零 bias	Local Combine	NRMSE	余弦	验收
M1	False	False	0.069284	0.99768	未通过
M1	False	True	0.069463	0.99768	未通过
M1	True	False	0.068494	0.99767	未通过
M1	True	True	0.068687	0.99765	未通过
M2	False	False	0.076315	0.99709	未通过
M2	False	True	0.075957	0.99712	未通过
M3	False	False	0.064471	0.99792	未通过
M3	False	True	0.06411	0.99795	未通过

以下结果为已批准时序/能耗模型的运行输出，不能据此声称 FP8 数值验收通过或真实模型精度得到验证。所有曲线及配对原始表均在 results 中保留。

M1：绝对延迟与能耗

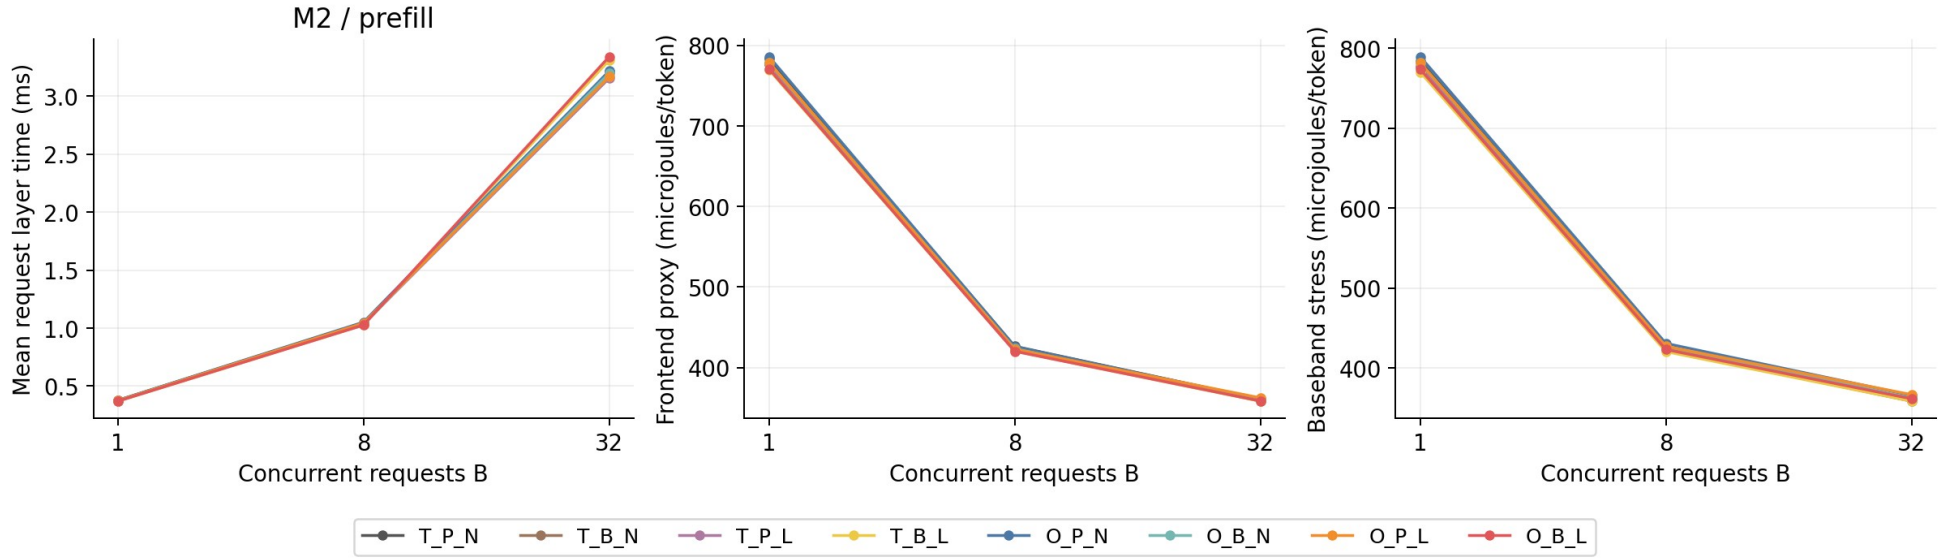


M1 prefill：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。

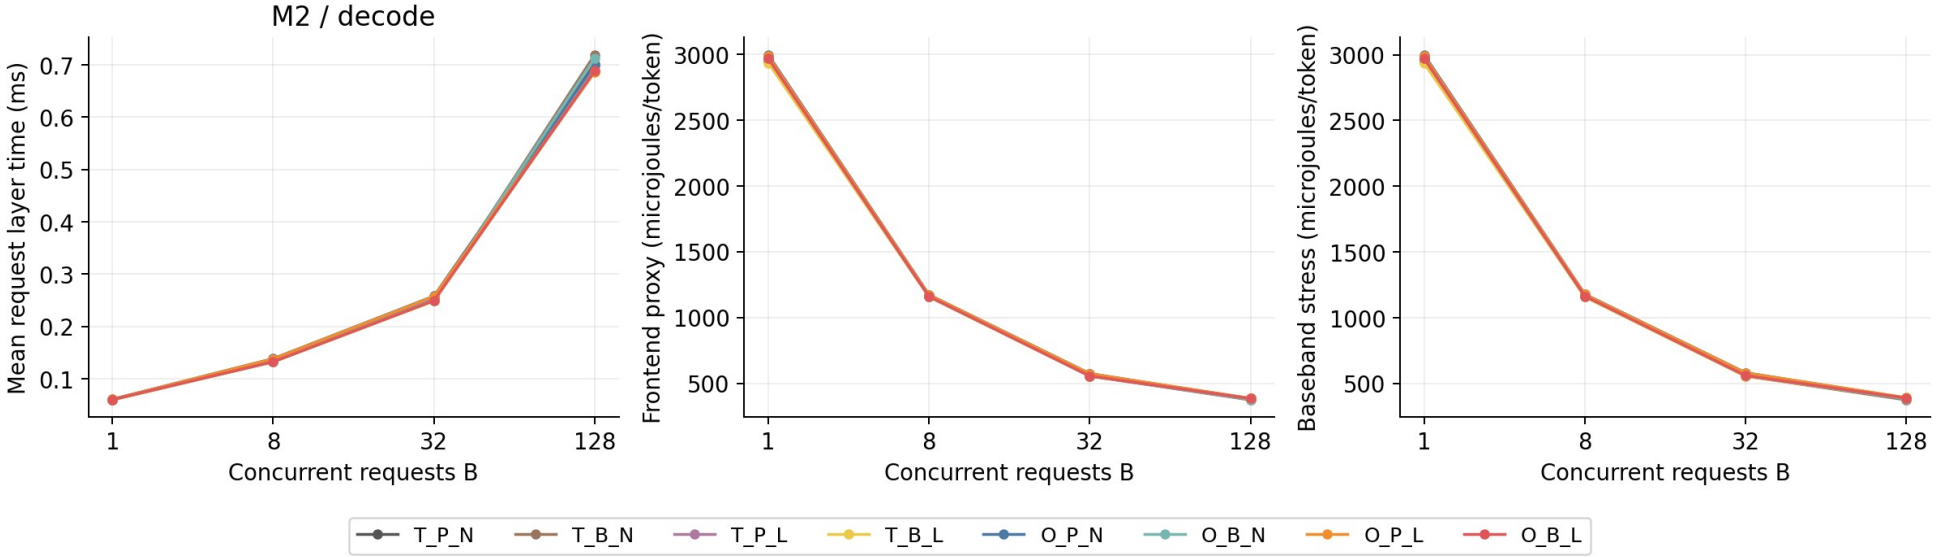


M1 decode：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。

M2：绝对延迟与能耗

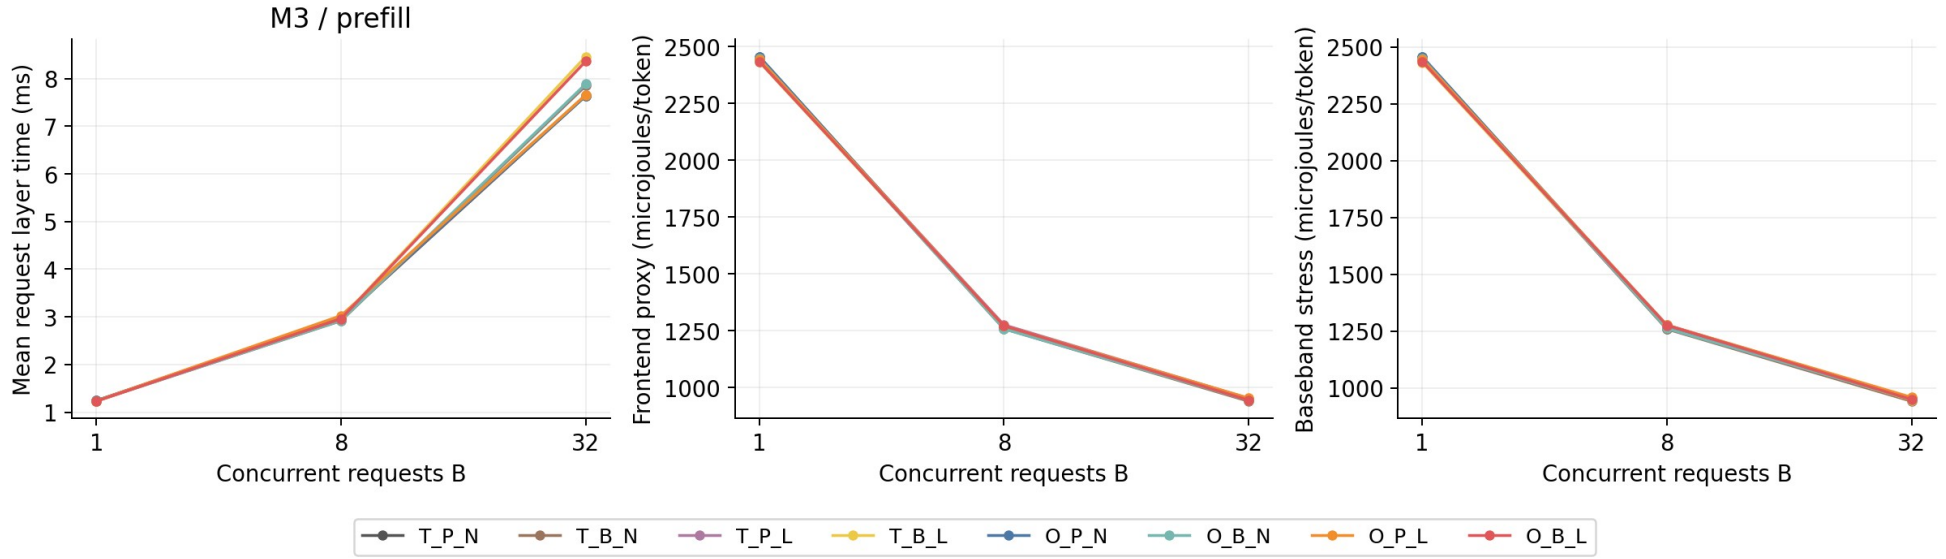


M2 prefill：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。

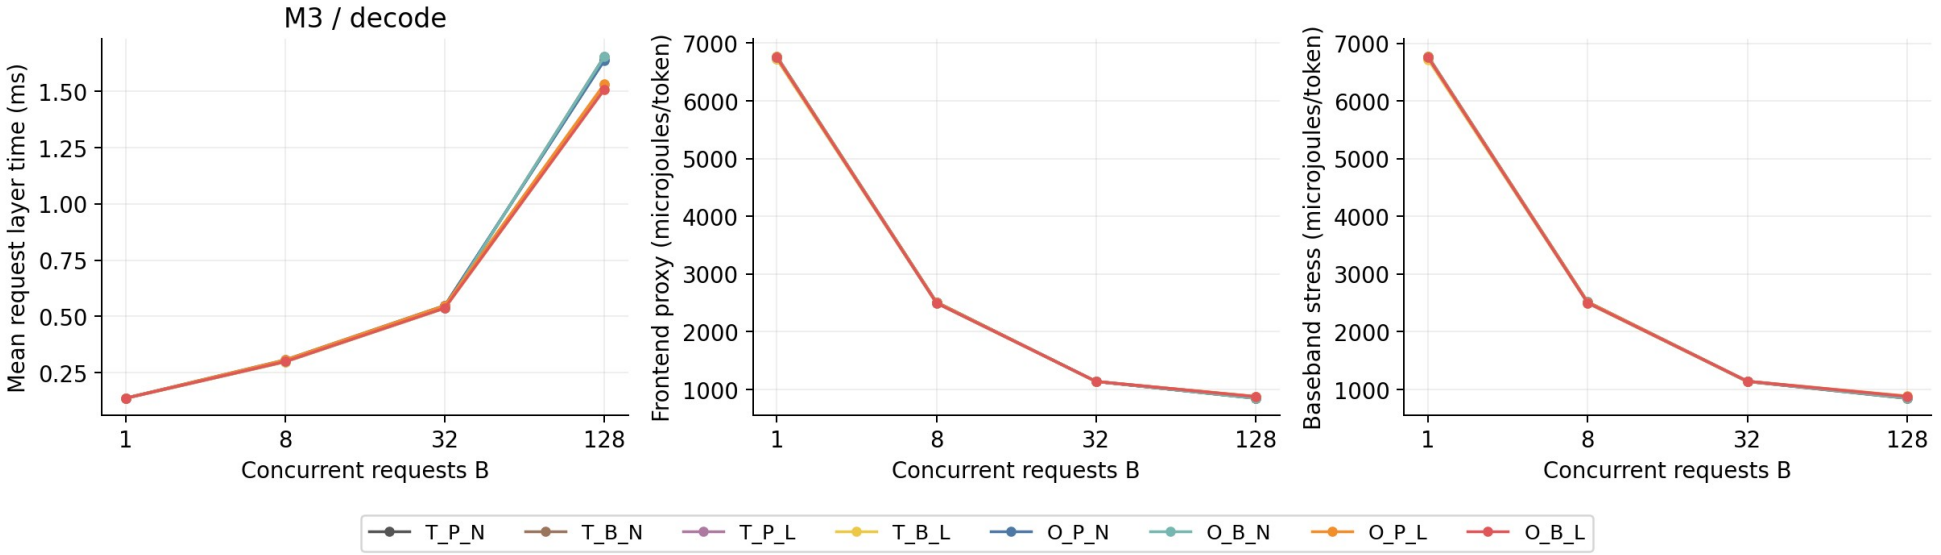


M2 decode：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。

M3：绝对延迟与能耗



M3 prefill：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。



M3 decode：八组合绝对延迟与两种能量账本；能量按实际完成 token 归一。

B32 请求层延迟分布

下列均值、p50 和 p95 单位为毫秒；分别先在每个种子的 128 个请求上计算，再取五种子平均。Prefill 为整个 prompt 完成延迟，Decode 为每个请求实际步数的平均单层延迟。token 分布和每轮活跃 B 另存原始 Parquet 与运行表。

模型	负载	策略	均值 ms	p50 ms	p95 ms
M1	prefill	T_P_N	7.574	7.5478	11.751
M1	prefill	T_B_N	7.7085	7.8321	11.87
M1	prefill	T_P_L	7.5513	7.5715	12.084
M1	prefill	T_B_L	8.0193	8.1812	12.096
M1	prefill	O_P_N	7.5788	7.7266	11.798
M1	prefill	O_B_N	7.748	7.8432	11.868
M1	prefill	O_P_L	7.5796	7.4752	11.941
M1	prefill	O_B_L	8.0068	8.1314	12.082
M1	decode	T_P_N	0.63747	0.6673	0.71166
M1	decode	T_B_N	0.63579	0.66809	0.71116
M1	decode	T_P_L	0.63799	0.66793	0.71235
M1	decode	T_B_L	0.6363	0.66871	0.71176
M1	decode	O_P_N	0.63779	0.66572	0.70758
M1	decode	O_B_N	0.63171	0.6642	0.70948
M1	decode	O_P_L	0.6383	0.66624	0.70828
M1	decode	O_B_L	0.63222	0.66473	0.71
M2	prefill	T_P_N	3.2134	3.1628	4.9156
M2	prefill	T_B_N	3.2043	3.1754	4.943
M2	prefill	T_P_L	3.1562	3.141	4.9541
M2	prefill	T_B_L	3.3113	3.3718	4.9066
M2	prefill	O_P_N	3.2178	3.168	4.9851
M2	prefill	O_B_N	3.1999	3.1634	4.8894
M2	prefill	O_P_L	3.1704	3.1739	5.0088
M2	prefill	O_B_L	3.3416	3.3737	4.9256
M2	decode	T_P_N	0.25388	0.26714	0.31439
M2	decode	T_B_N	0.24925	0.26767	0.30265
M2	decode	T_P_L	0.25318	0.26645	0.31387
M2	decode	T_B_L	0.24854	0.26697	0.30215
M2	decode	O_P_N	0.25783	0.26728	0.31199
M2	decode	O_B_N	0.24985	0.26839	0.30128
M2	decode	O_P_L	0.25711	0.26645	0.3113
M2	decode	O_B_L	0.24914	0.26761	0.30078
M3	prefill	T_P_N	7.6385	7.4805	12.376
M3	prefill	T_B_N	7.8517	7.7687	12.279

模型	负载	策略	均值 ms	p50 ms	p95 ms
M3	prefill	T_P_L	7.6525	7.3547	12.697
M3	prefill	T_B_L	8.4621	8.5681	12.576
M3	prefill	O_P_N	7.6379	7.5788	12.421
M3	prefill	O_B_N	7.8879	7.7786	12.447
M3	prefill	O_P_L	7.6564	7.5063	12.775
M3	prefill	O_B_L	8.3635	8.4102	12.653
M3	decode	T_P_N	0.54698	0.56901	0.609
M3	decode	T_B_N	0.53697	0.56737	0.61913
M3	decode	T_P_L	0.54651	0.56864	0.60855
M3	decode	T_B_L	0.53651	0.56693	0.61879
M3	decode	O_P_N	0.54869	0.56649	0.60501
M3	decode	O_B_N	0.5379	0.56764	0.61754
M3	decode	O_P_L	0.54822	0.56602	0.60469
M3	decode	O_B_L	0.53744	0.56729	0.6173

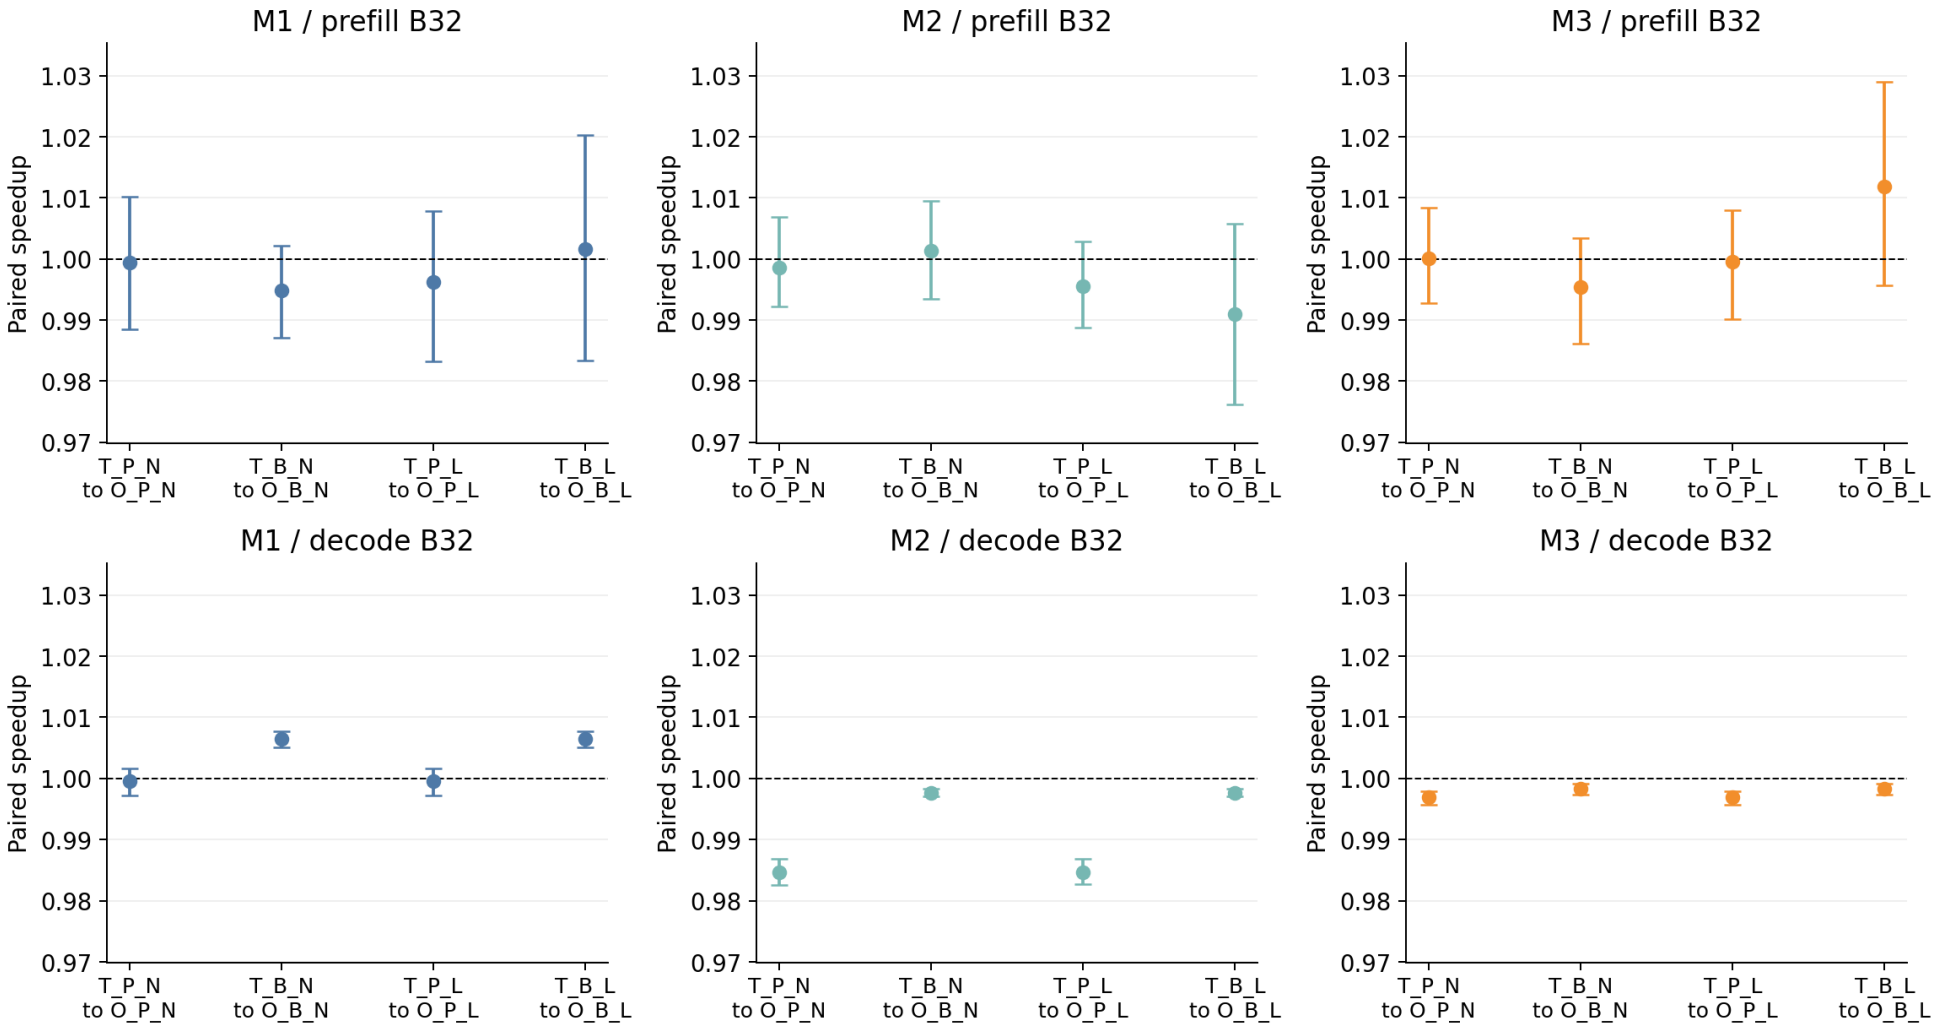
6. 结果整理与对照

重点表采用 B32。完整 B=1/8/32 及 Decode B128 结果见 aggregate.csv、raw_runs.csv 与对应图表。跨模型仅讨论各自相对基线的变化，不把不同矩阵规模导致的原始延迟差异归因于通信机制。

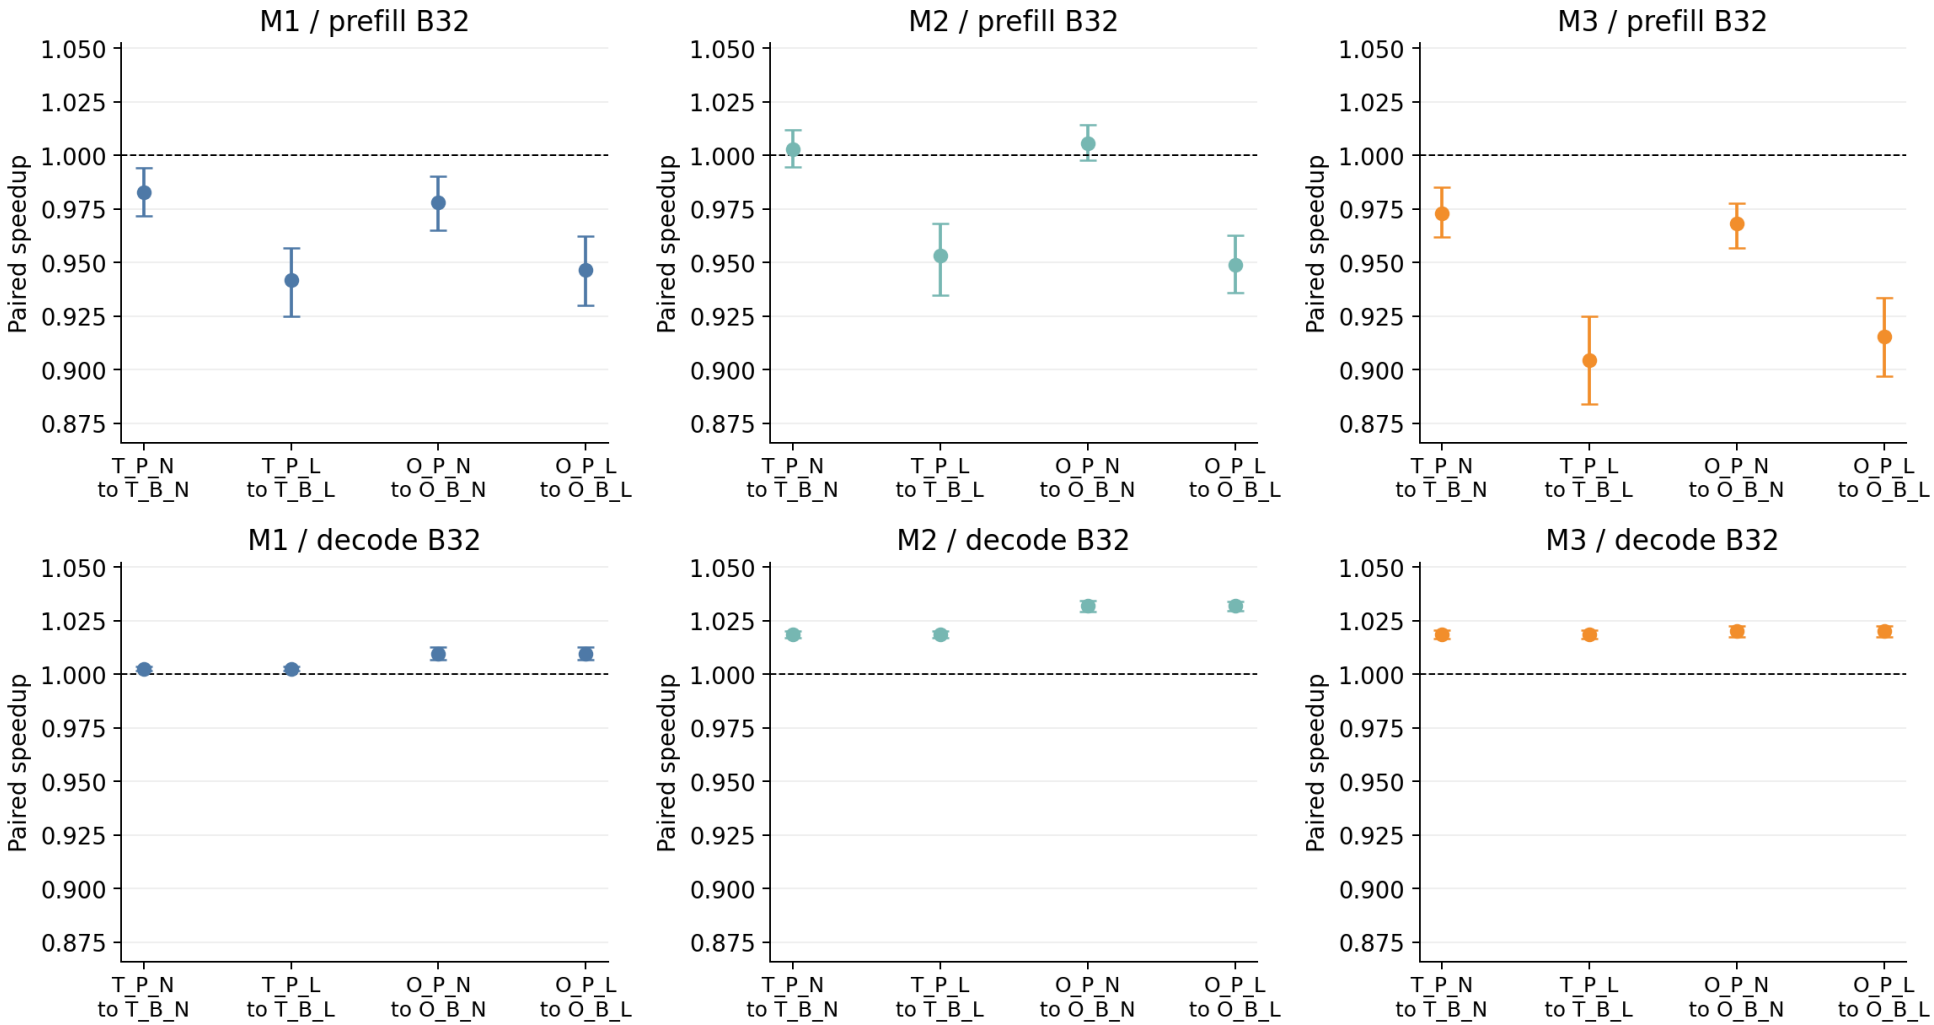
模型	负载	O_B_L 加速比 [95%区间]	前端节能	压力节能
M1	decode	1.0083 [1.0067, 1.0102]	0.348%	0.142%
M1	prefill	0.9459 [0.9308, 0.9616]	-0.702%	-0.965%
M2	decode	1.0190 [1.0174, 1.0208]	2.521%	1.991%
M2	prefill	0.9617 [0.9492, 0.9746]	0.623%	-0.199%
M3	decode	1.0178 [1.0159, 1.0197]	-0.211%	-0.490%
M3	prefill	0.9133 [0.8921, 0.9351]	0.226%	-0.072%

通信字节减少与请求延迟变化分别如下；节省为正、增加为负。空口字节按物理发射一次计，不把广播接收方数乘回发射字节。专家批量变化会改变权重复用和 eDRAM 流量；以下 T→O 指 T_P_N→O_B_L 整组对比。

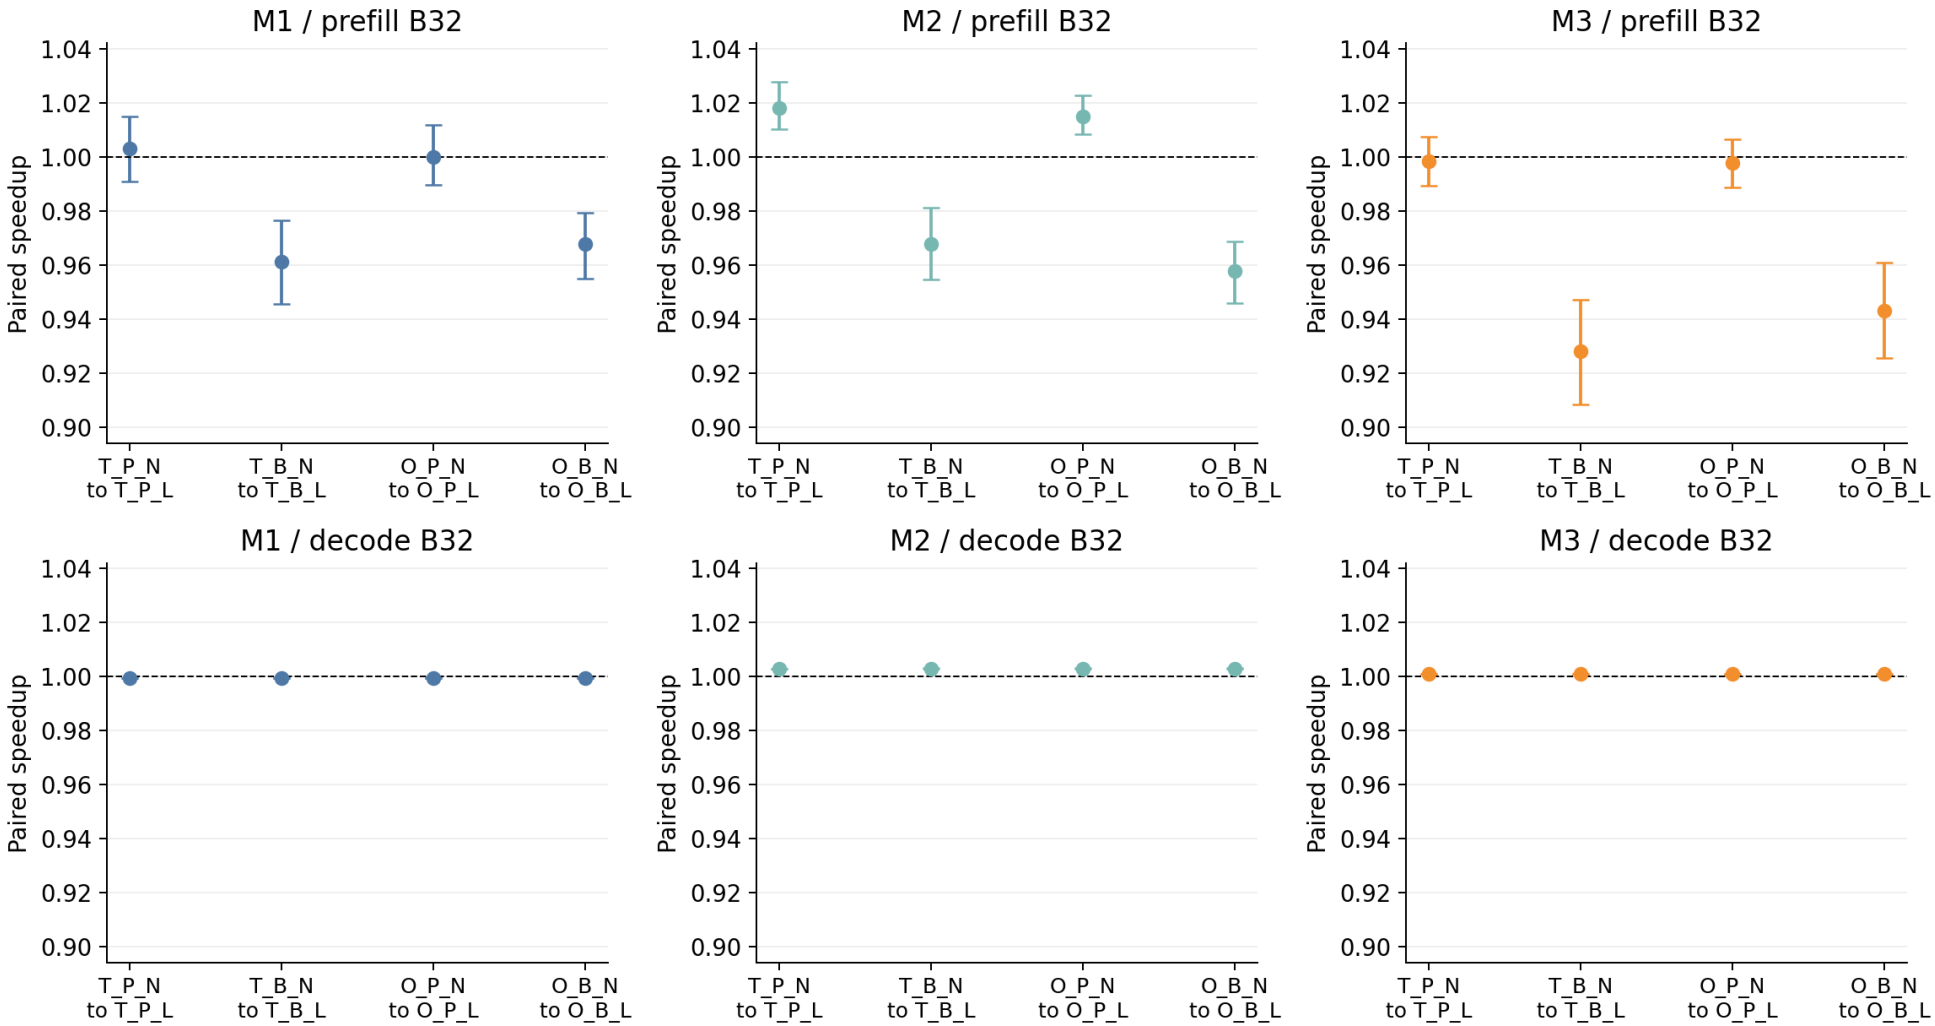
模型	负载	Dispatch 节省	Return 节省	平均专家批量 T→O	eDRAM 读写 MB/token T→O	请求延迟变化
M1	decode	71.78%	4.91%	2.509 → 2.515	41.490 → 41.463	-0.824%
M1	prefill	71.82%	4.75%	4.551 → 3.942	23.827 → 27.251	+5.714%
M2	decode	83.47%	17.51%	1.859 → 1.916	21.551 → 20.993	-1.868%
M2	prefill	83.47%	17.46%	4.002 → 3.713	10.770 → 11.537	+3.988%
M3	decode	82.02%	14.70%	2.446 → 2.446	40.366 → 40.433	-1.744%
M3	prefill	82.03%	14.71%	4.110 → 3.810	24.959 → 26.833	+9.492%



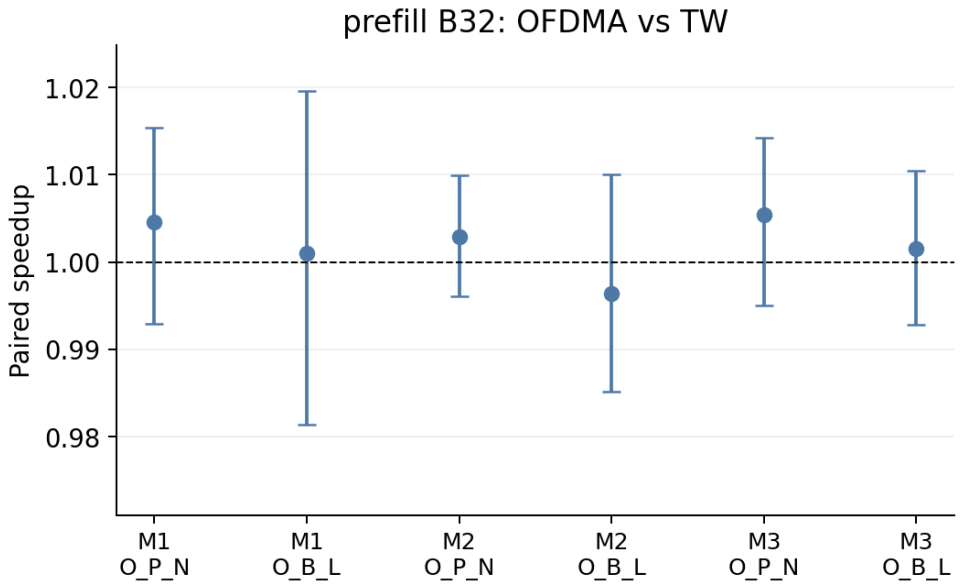
ofdma：其它两项固定时的四组条件效应；95%区间；不能将三机制百分比直接相加。

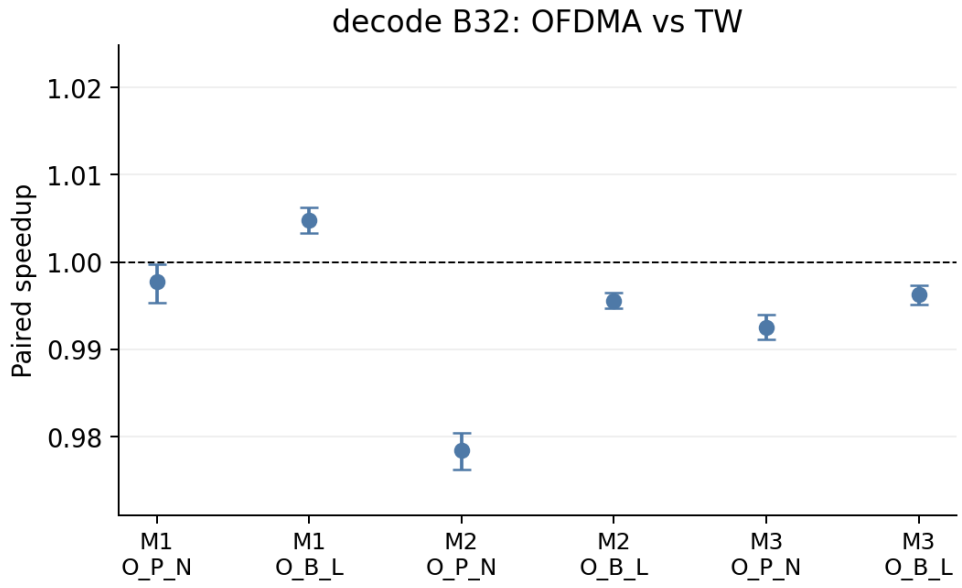


broadcast：其它两项固定时的四组条件效应；95%区间；不能将三机制百分比直接相加。

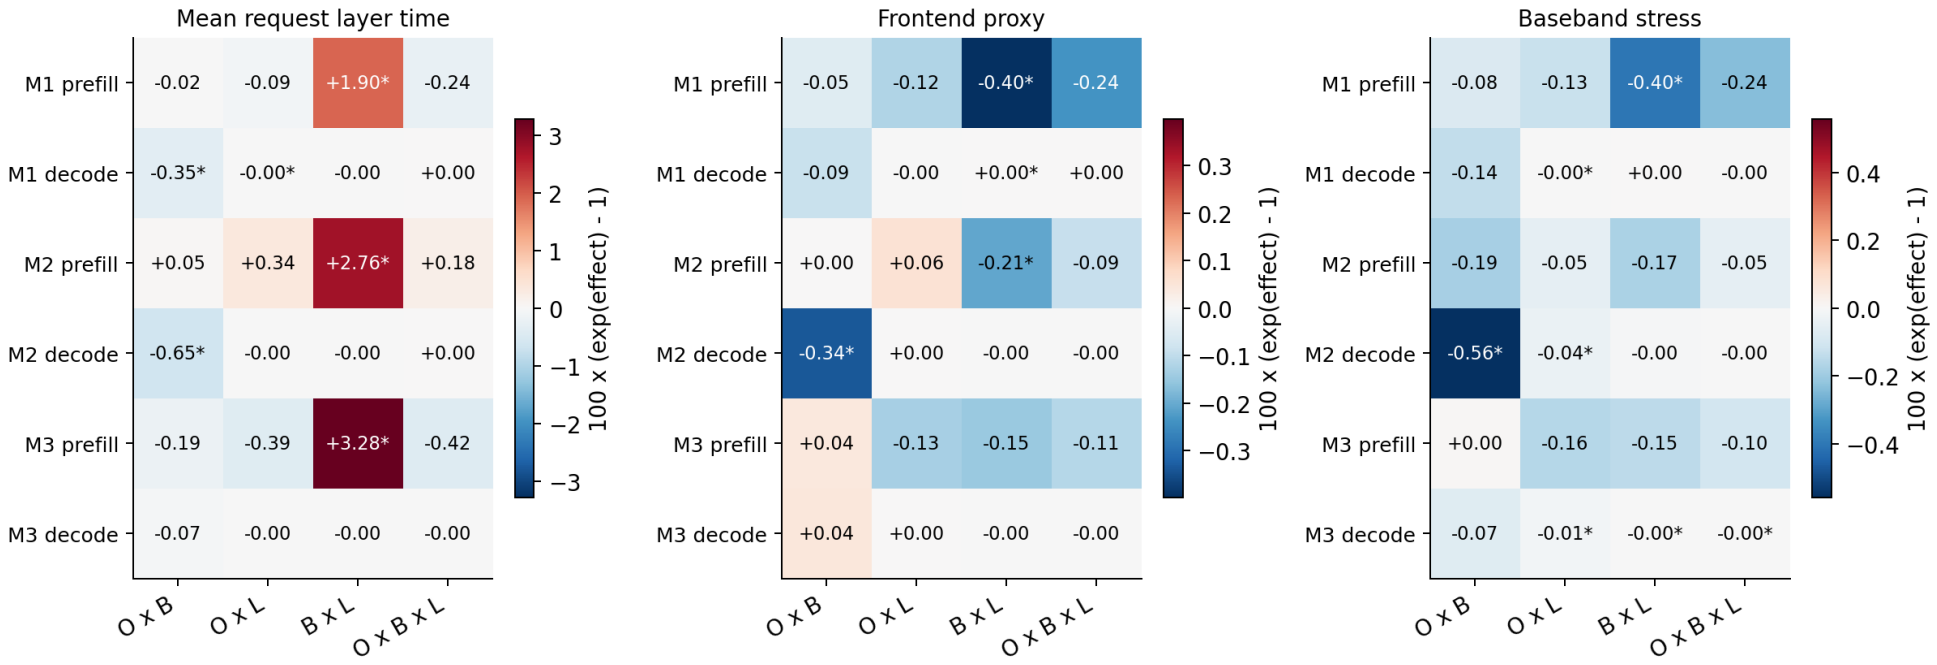


local_combine：其它两项固定时的四组条件效应；95%区间；不能将三机制百分比直接相加。

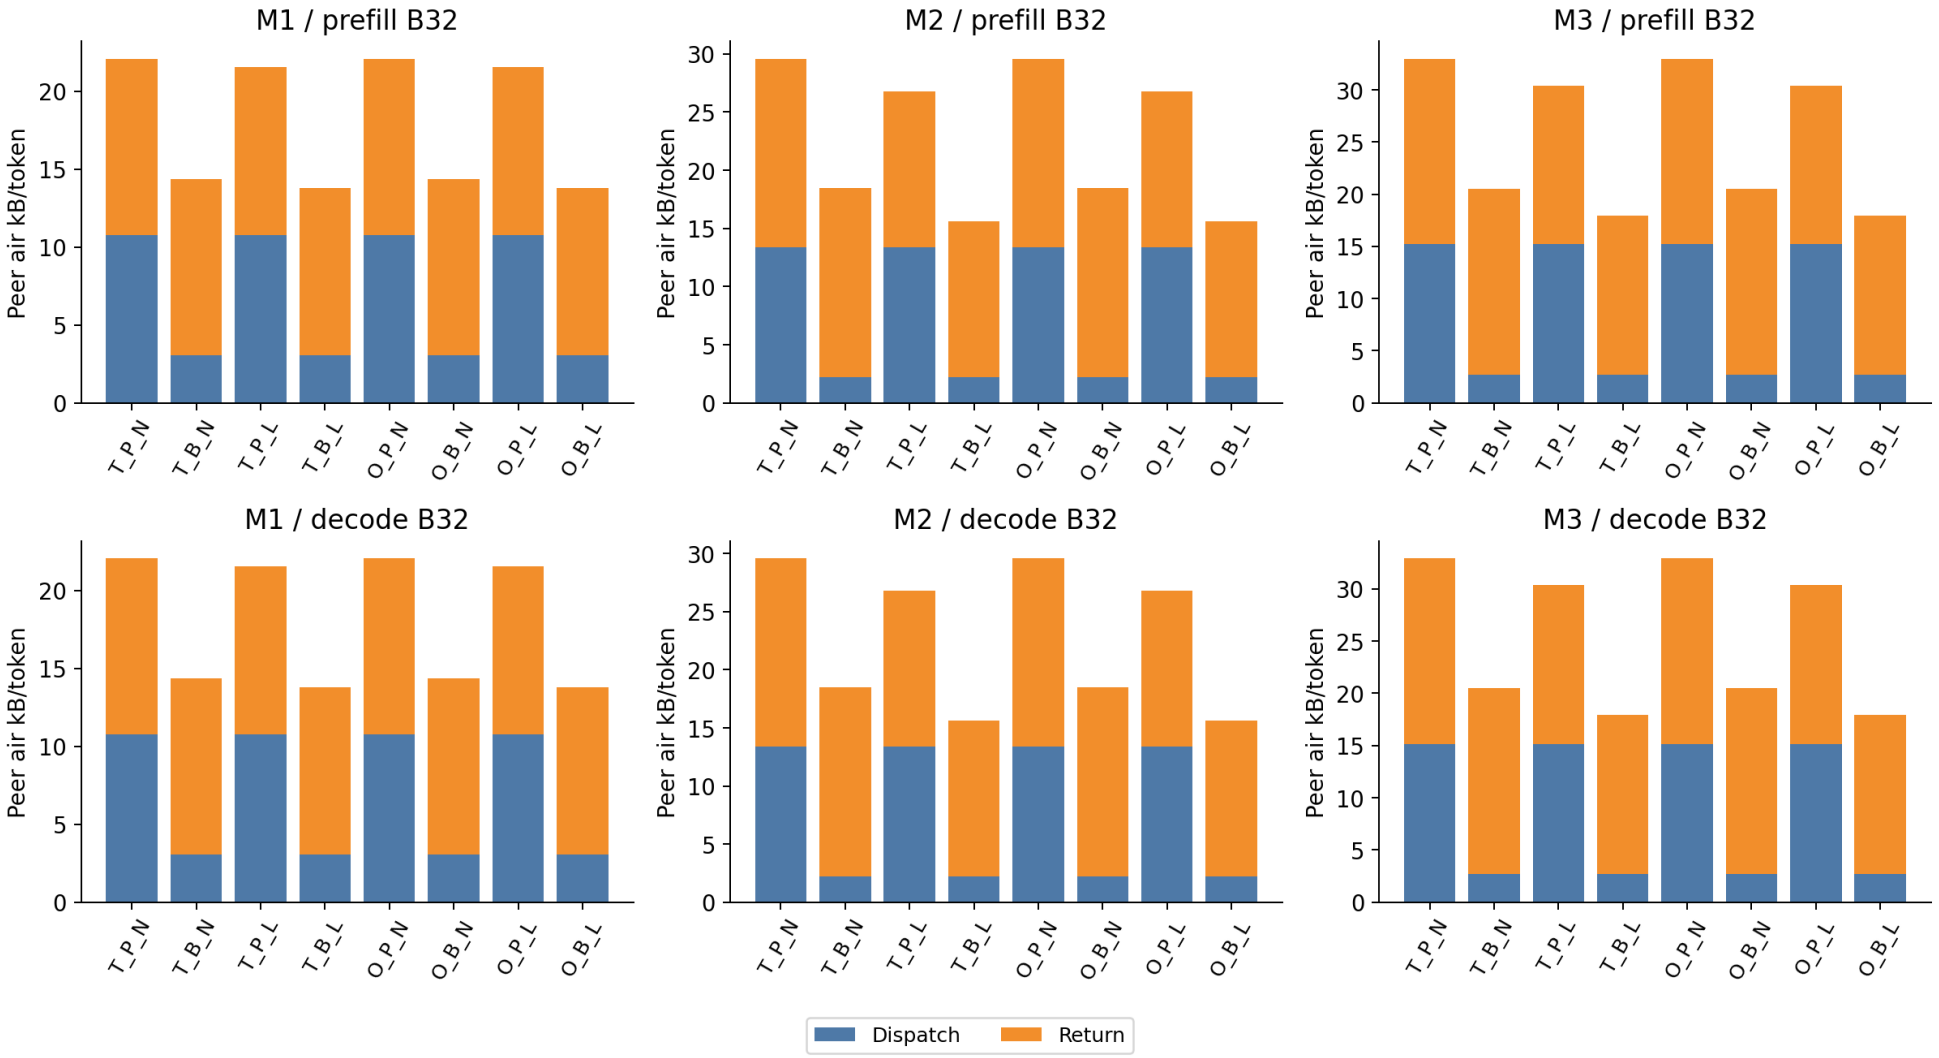




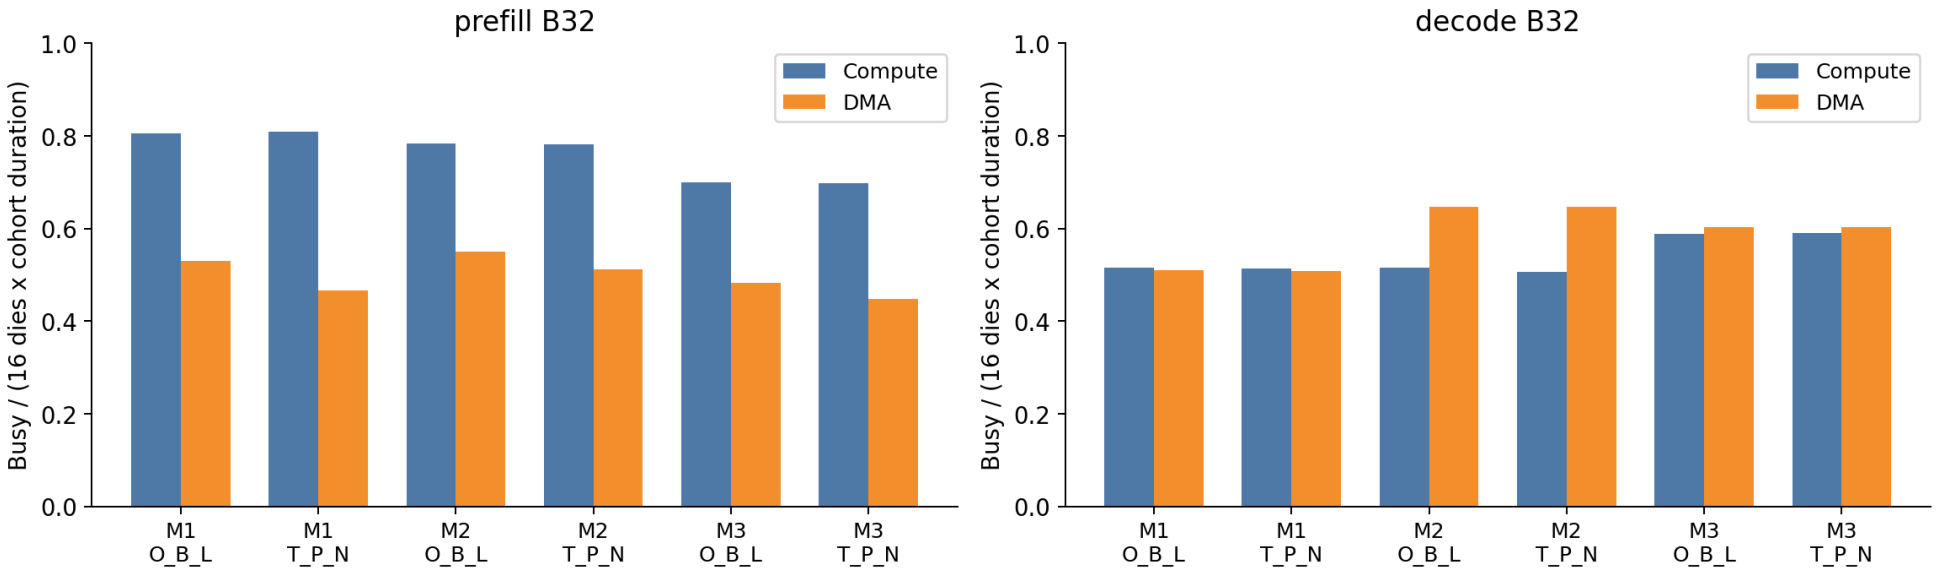
强 TDMA 反证：O_P_N/O_B_L 分别相对包粒度 TW_P_N/TW_B_L。



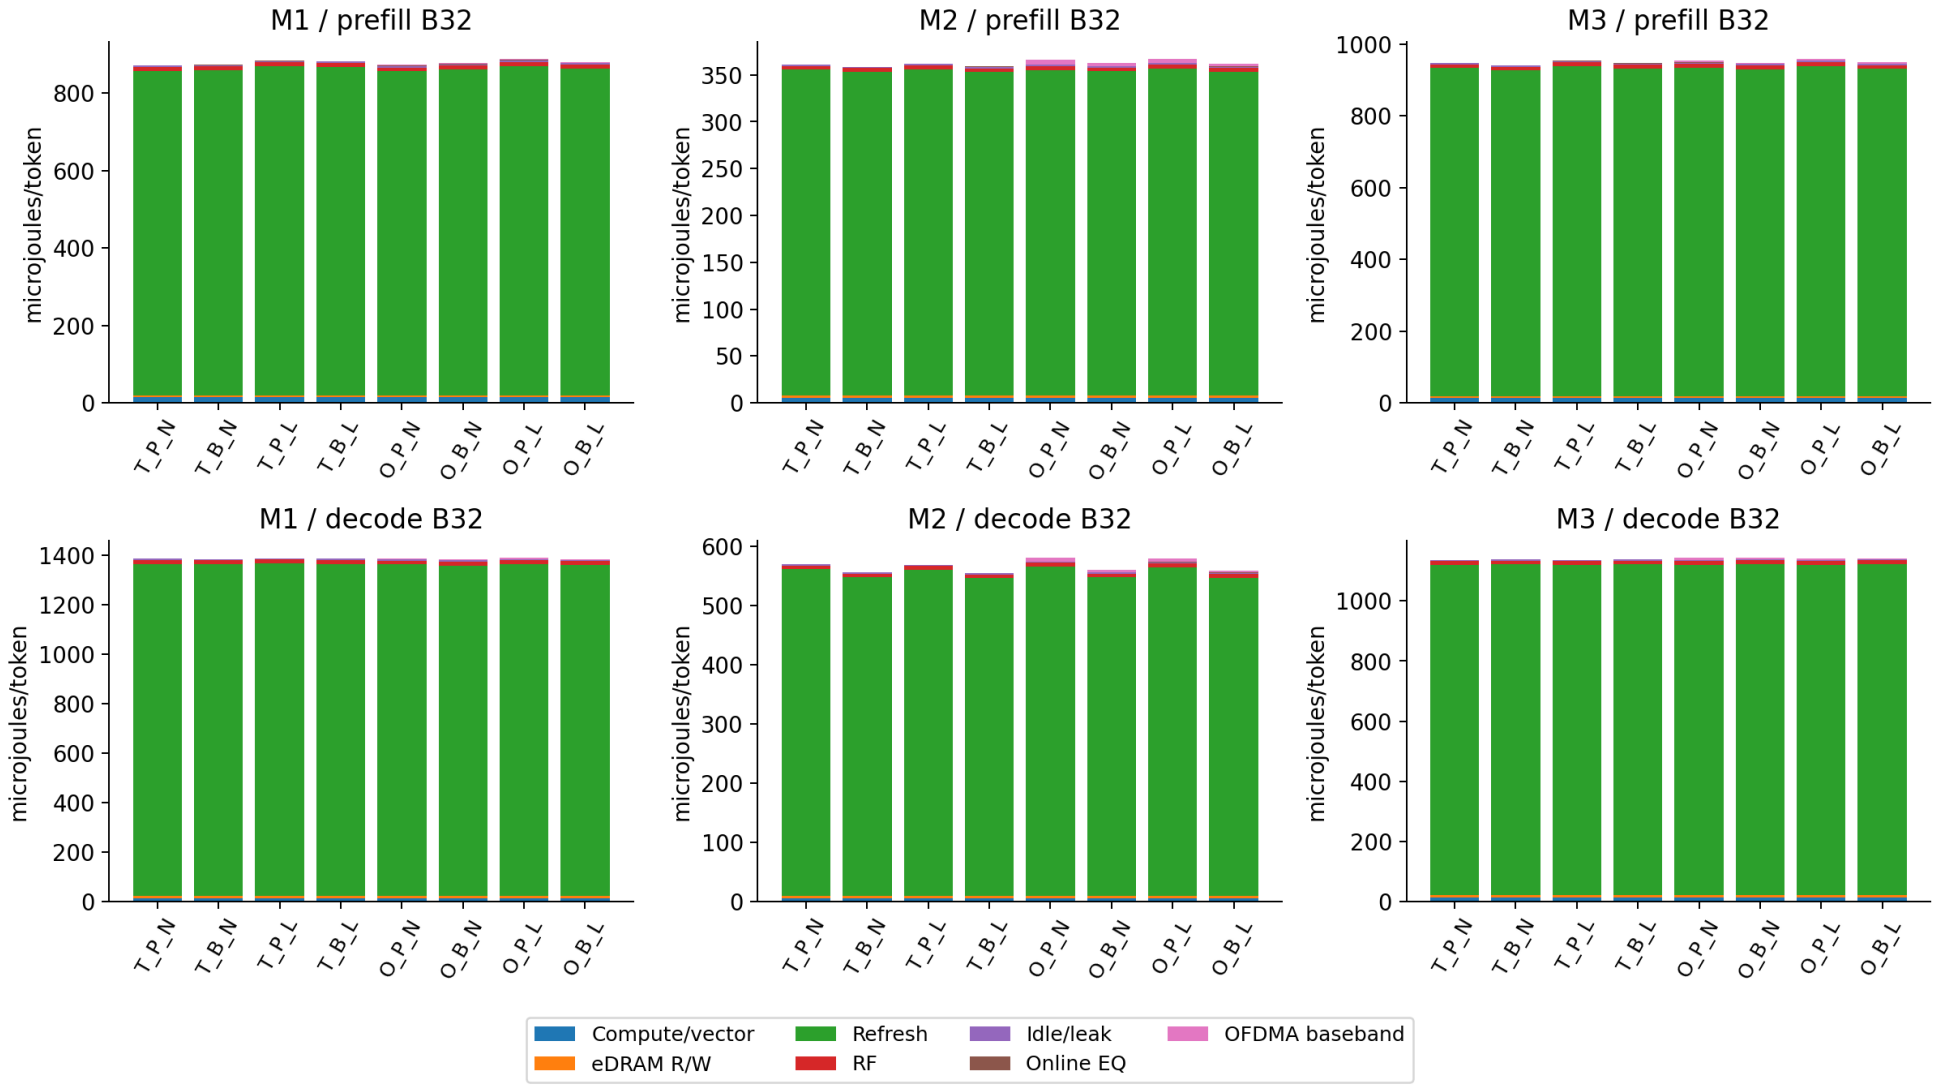
二阶与三阶交互：标准 2^3 因子效应的乘性形式；星号表示配对 95%区间不含零效应。数值不是可相加的单机制节能率。



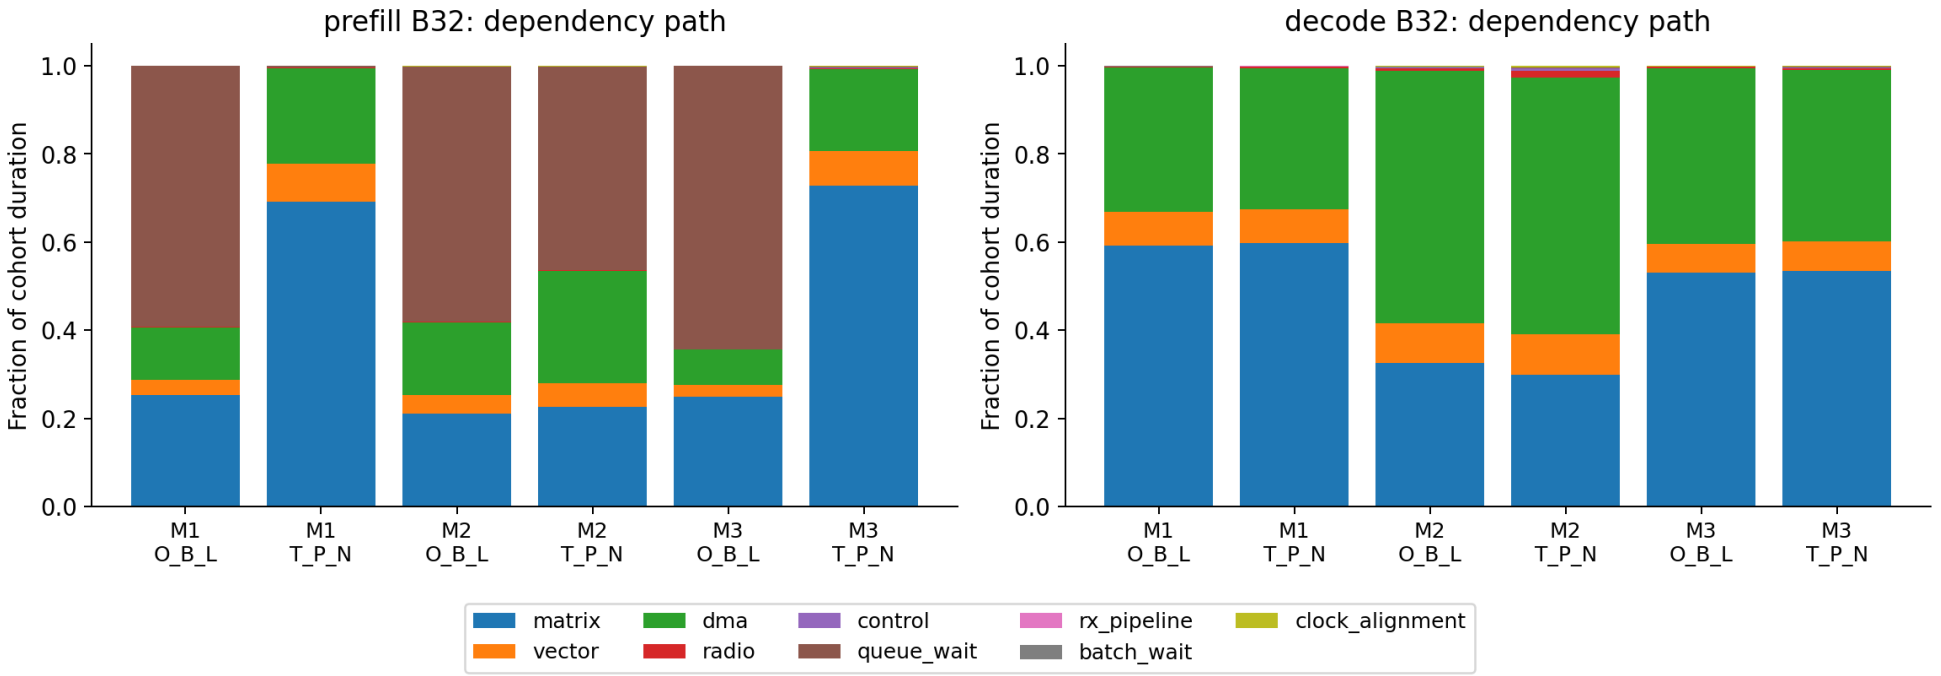
通信局部效果：Dispatch 与 Return 空口字节；广播只按一次发射计量，含包头、CRC 和 scale；Base 输入/输出另记。



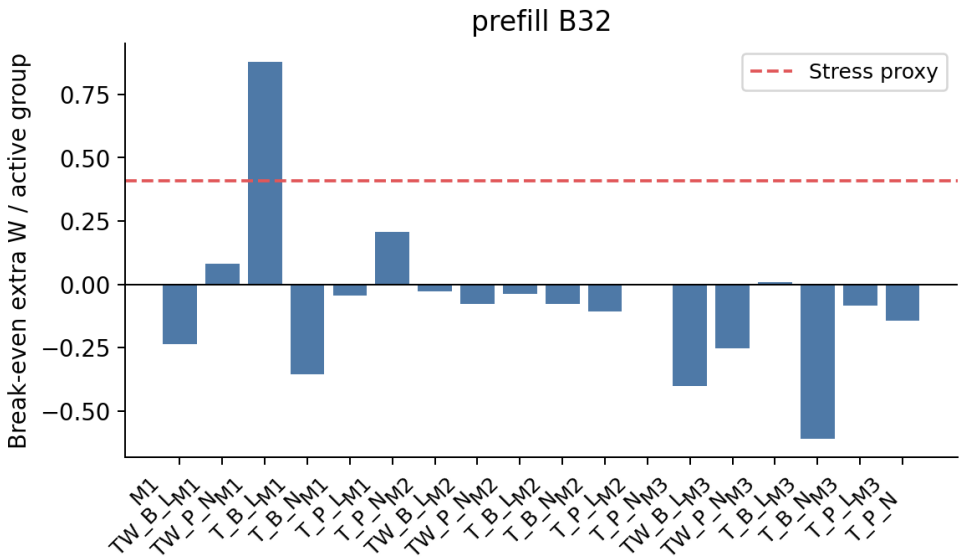
资源 busy-time 按 16 个 Die 可用时间归一。计算与 DMA 可重叠，因此两项不相加解释整层延迟。

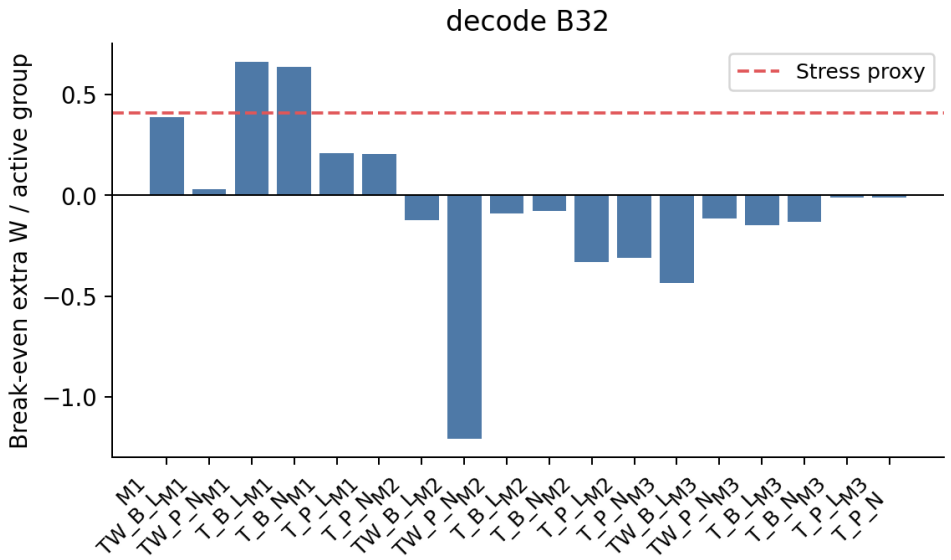


B32 下的能耗分项；刷新、在线均衡和 OFDMA 基带压力分别保留，不隐藏负收益。



依赖路径包含计算、DMA、无线、控制与显式等待；分项闭合到 cohort 完成时间，区别于可重叠的资源 busy-time。





在线 EQ 维持 20mW 时的 OFDMA 额外基带功耗盈亏阈值；负值表示零额外功耗也不能节能。

广播在同一输入发往多个 Die 时复用空口，单目的退化为单播。P2P 基线也按目的 Die 去重。Local Combine 只合并同 token 同 Die 的贡献，是否减少返回取决于实际命中重合；两个 shared 贡献的 owner/buddy 重合也已计入。

均匀无放回路由中，令 p=1−C(E−E/16,k)/C(E,k)。无 shared 模型的远端目的 Die 数期望为 15p；M3 的 buddy 必达，故为 1+14p。下表与冻结 trace 实际命中数对照，排除 owner 本地贡献；不把 Top-k 直接当作通信份数。

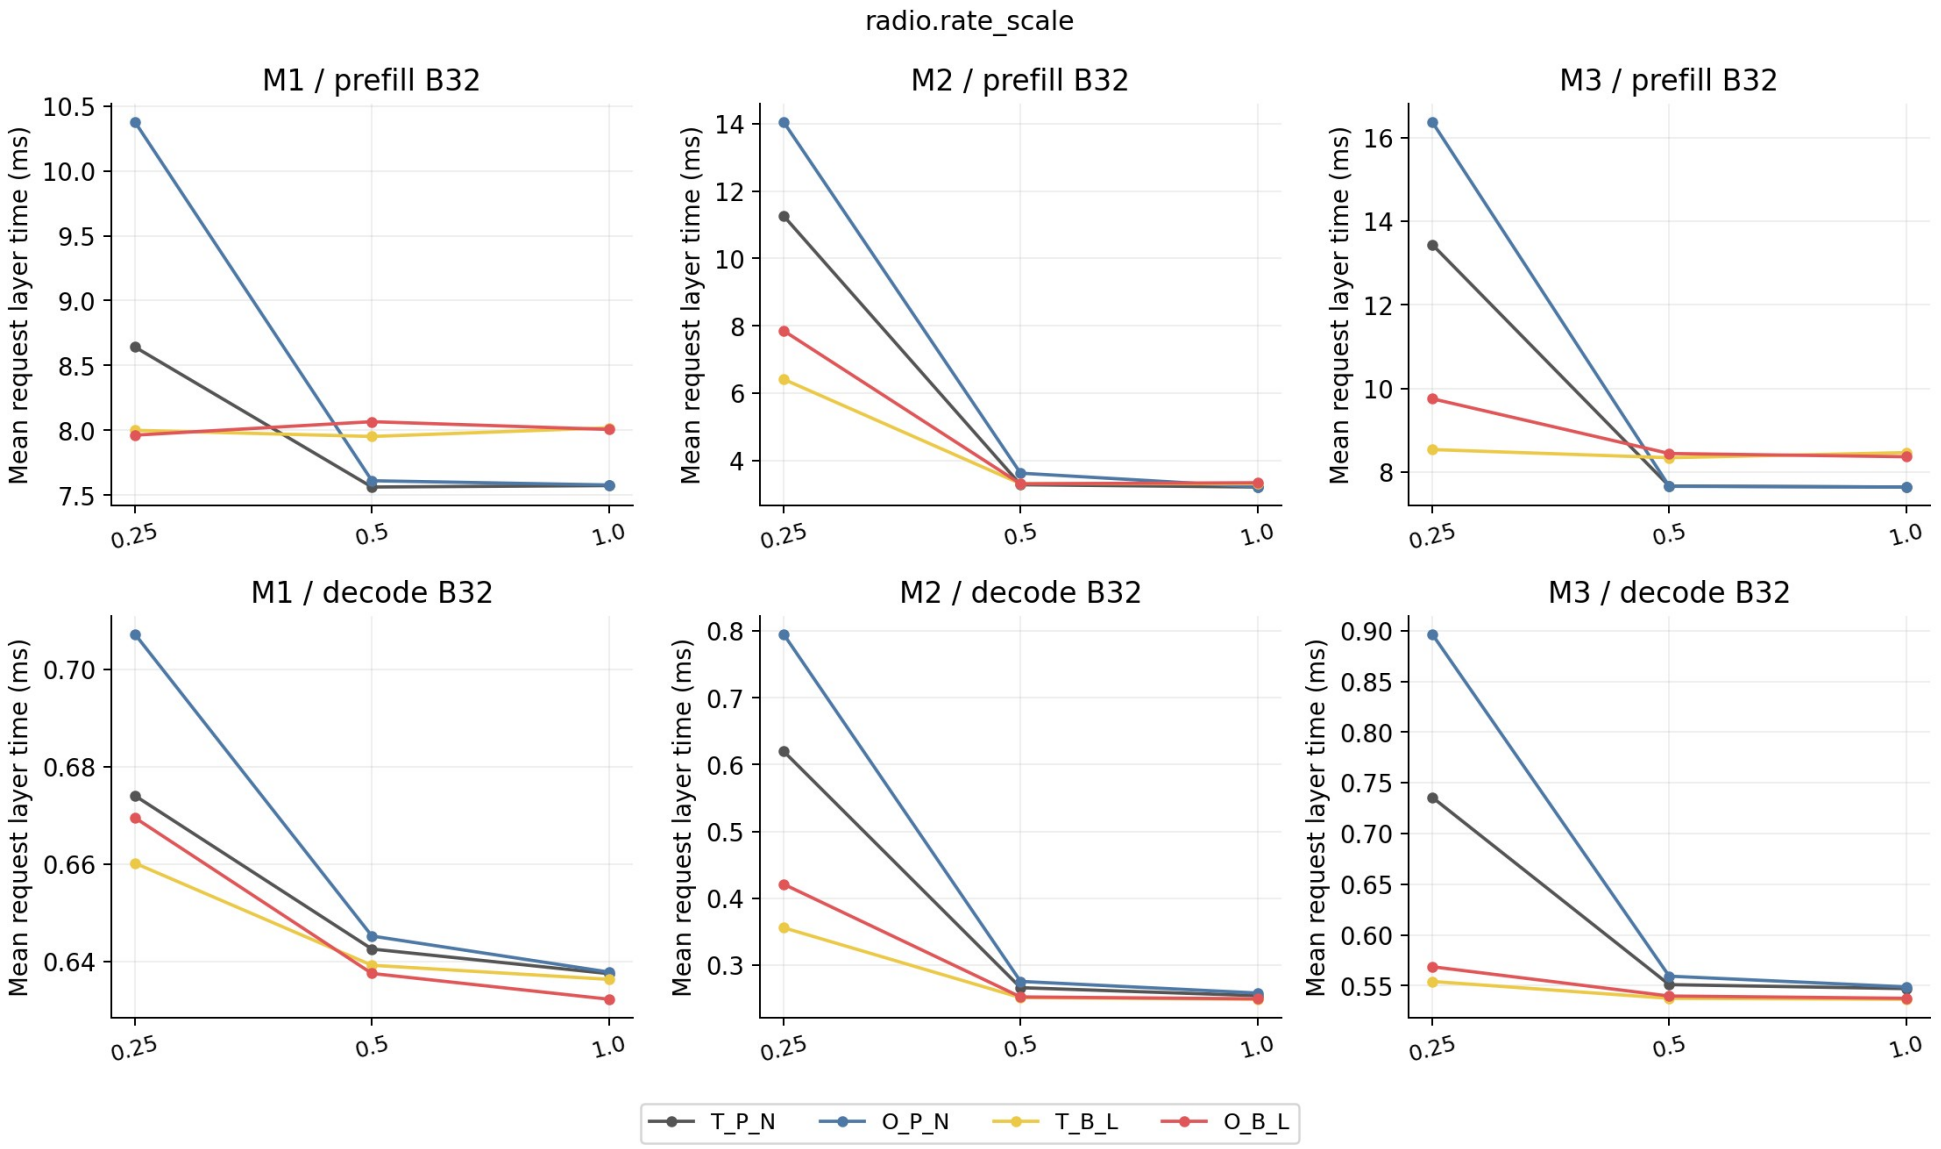
模型	负载	均匀理论远端 Die 数	实际远端 Die 数	实际 token 数
M1	decode	3.5685	3.5692	39808
M1	prefill	3.5685	3.5737	14973
M2	decode	6.1842	6.192	39876
M2	prefill	6.1842	6.1908	15338
M3	decode	5.6516	5.6506	39936
M3	prefill	5.6516	5.6562	16049

OFDMA 保持同一满带宽锚点，另付 14/17 效率损失。与 TW 对照用于判断收益是否依赖帧空尾；不能把“可并发发送”直接等同于更低完整层延迟。factorial_interactions.csv 给出对数尺度二阶和三阶交互，三项百分比不可直接相加。

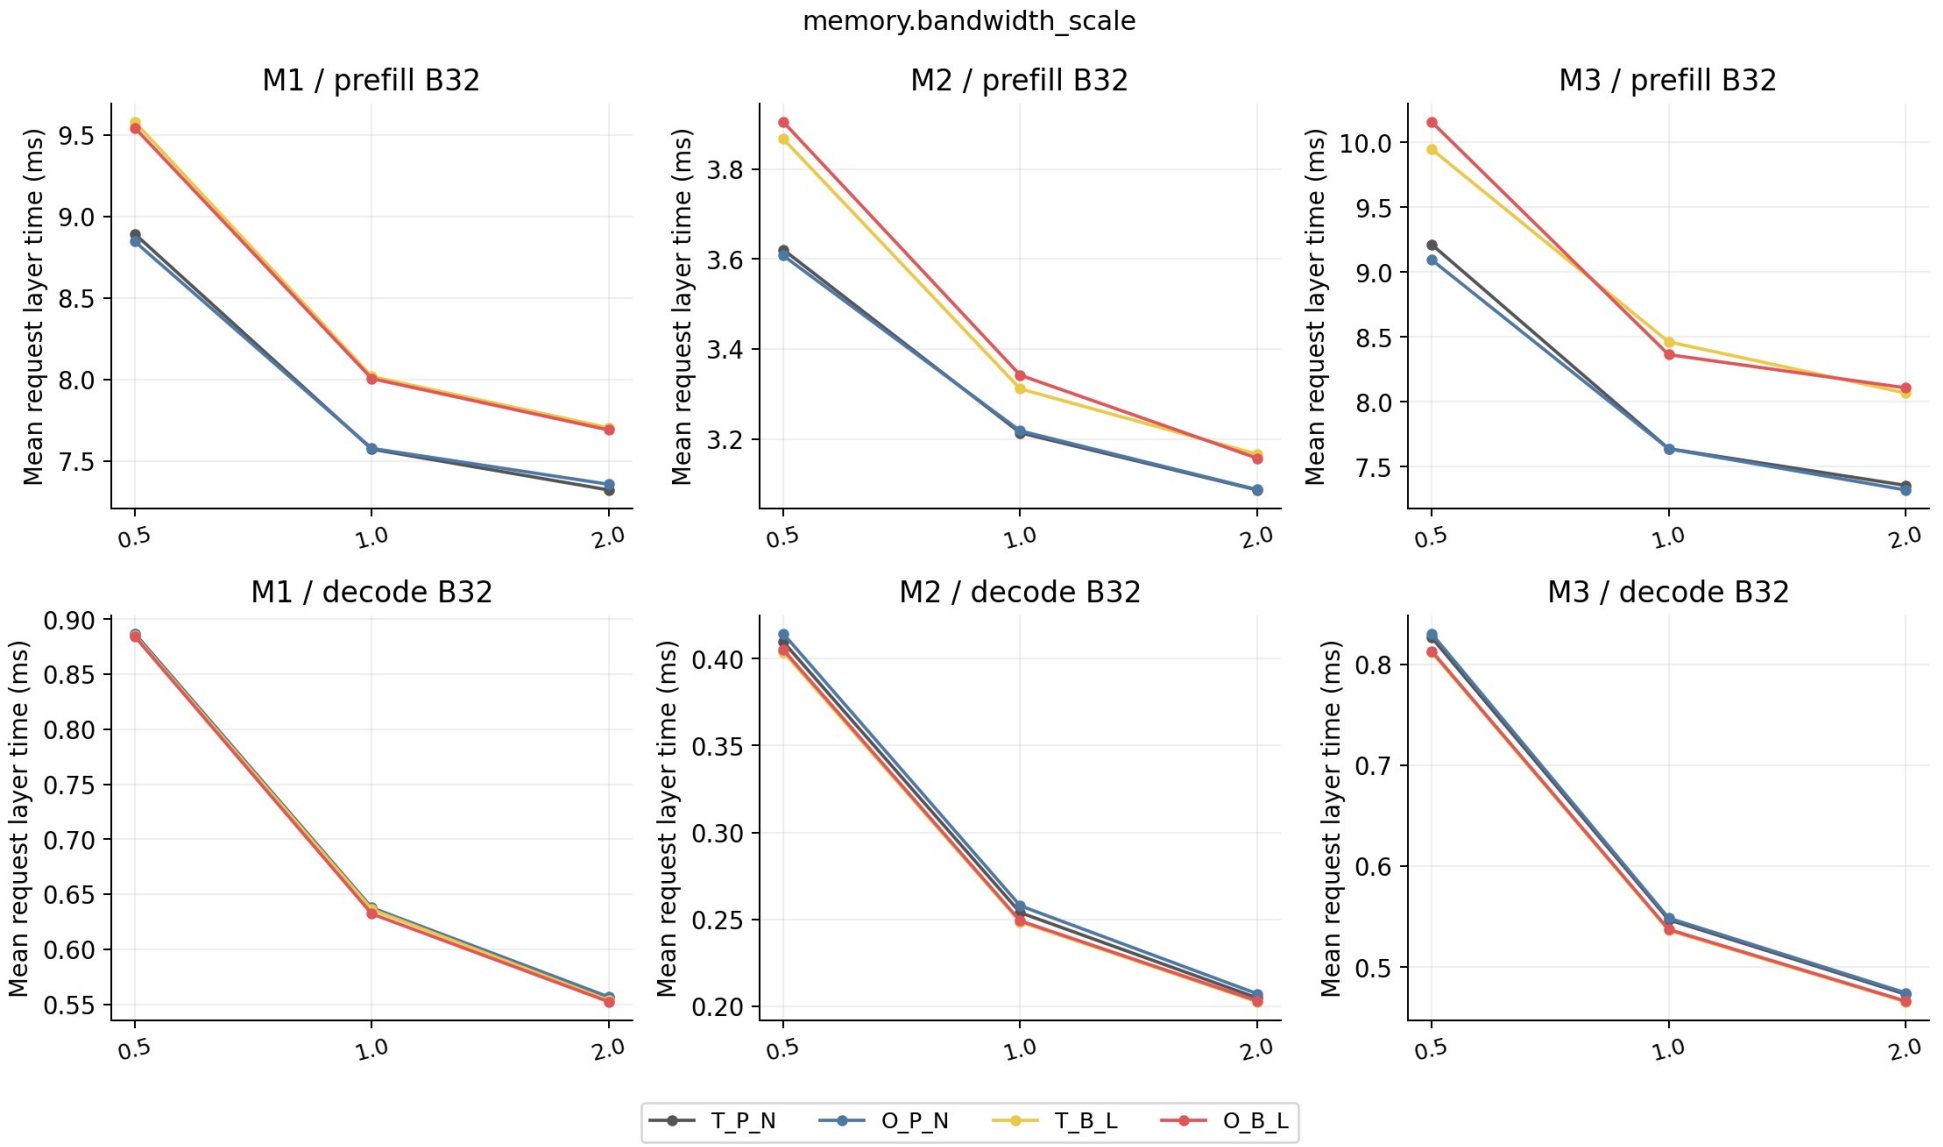
交互采用标准 2^3 因子效应：T/P/N 编码−1，O/B/L 编码+1；对因素集合 S 计算 effect=Σ[∏(x_i, i∈S)×log(metric)]/4。乘性形式为 exp(effect)，对应回归交互系数的两倍。factorial_summary.csv 提供全部八组合共同配对、按种子/cohort 重抽的 95%区间。能量对比的公共 token 分母在该零和对比中消去。

敏感性与不确定性

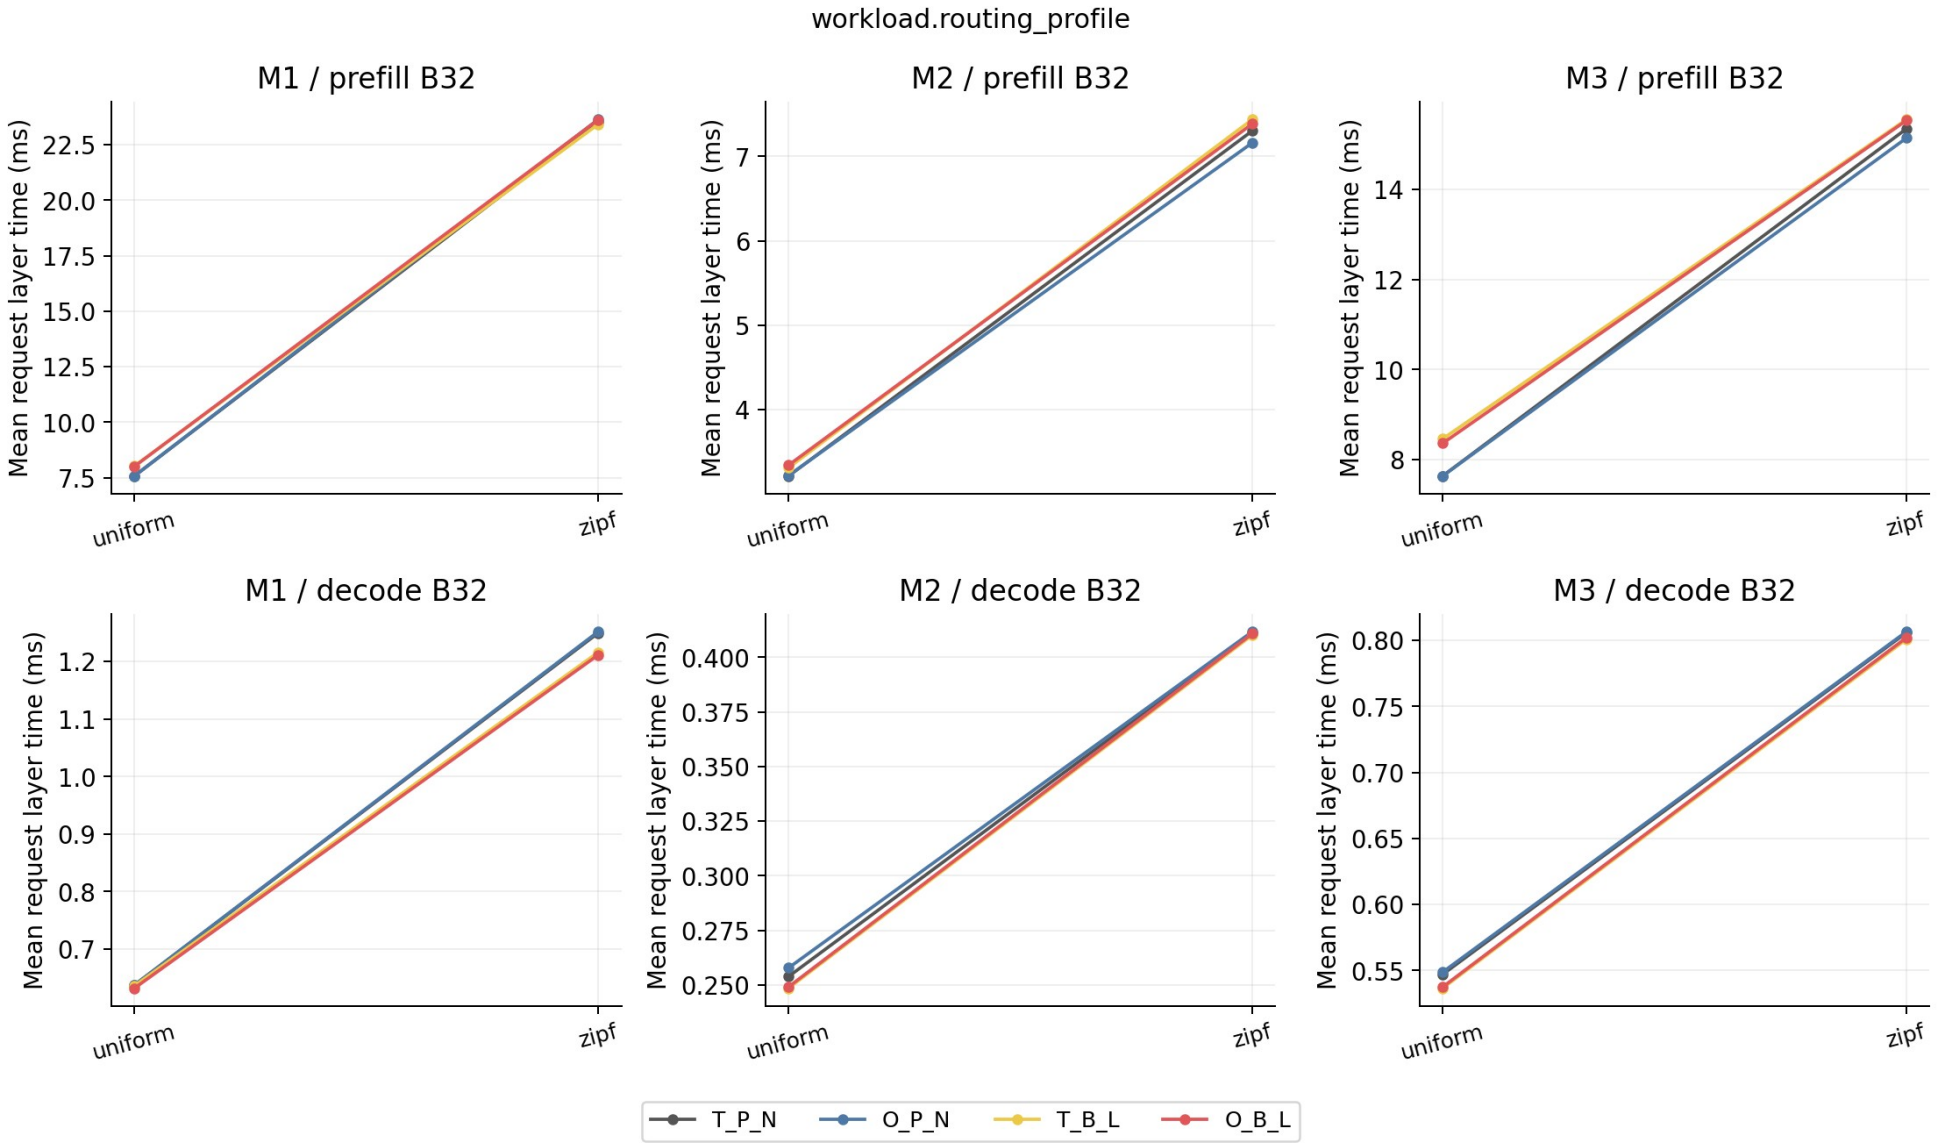
15 个单因素轴的三个指标均已出图：速率降额、广播速率、计算利用率、内存带宽与能耗修正、刷新周期、计算能耗、OFDMA 和 EQ 功耗、帧长、广播监听范围、路由热点、Decode 复用、待机及向量能耗倍率。所有曲线均含默认点，且默认点来自主实验。



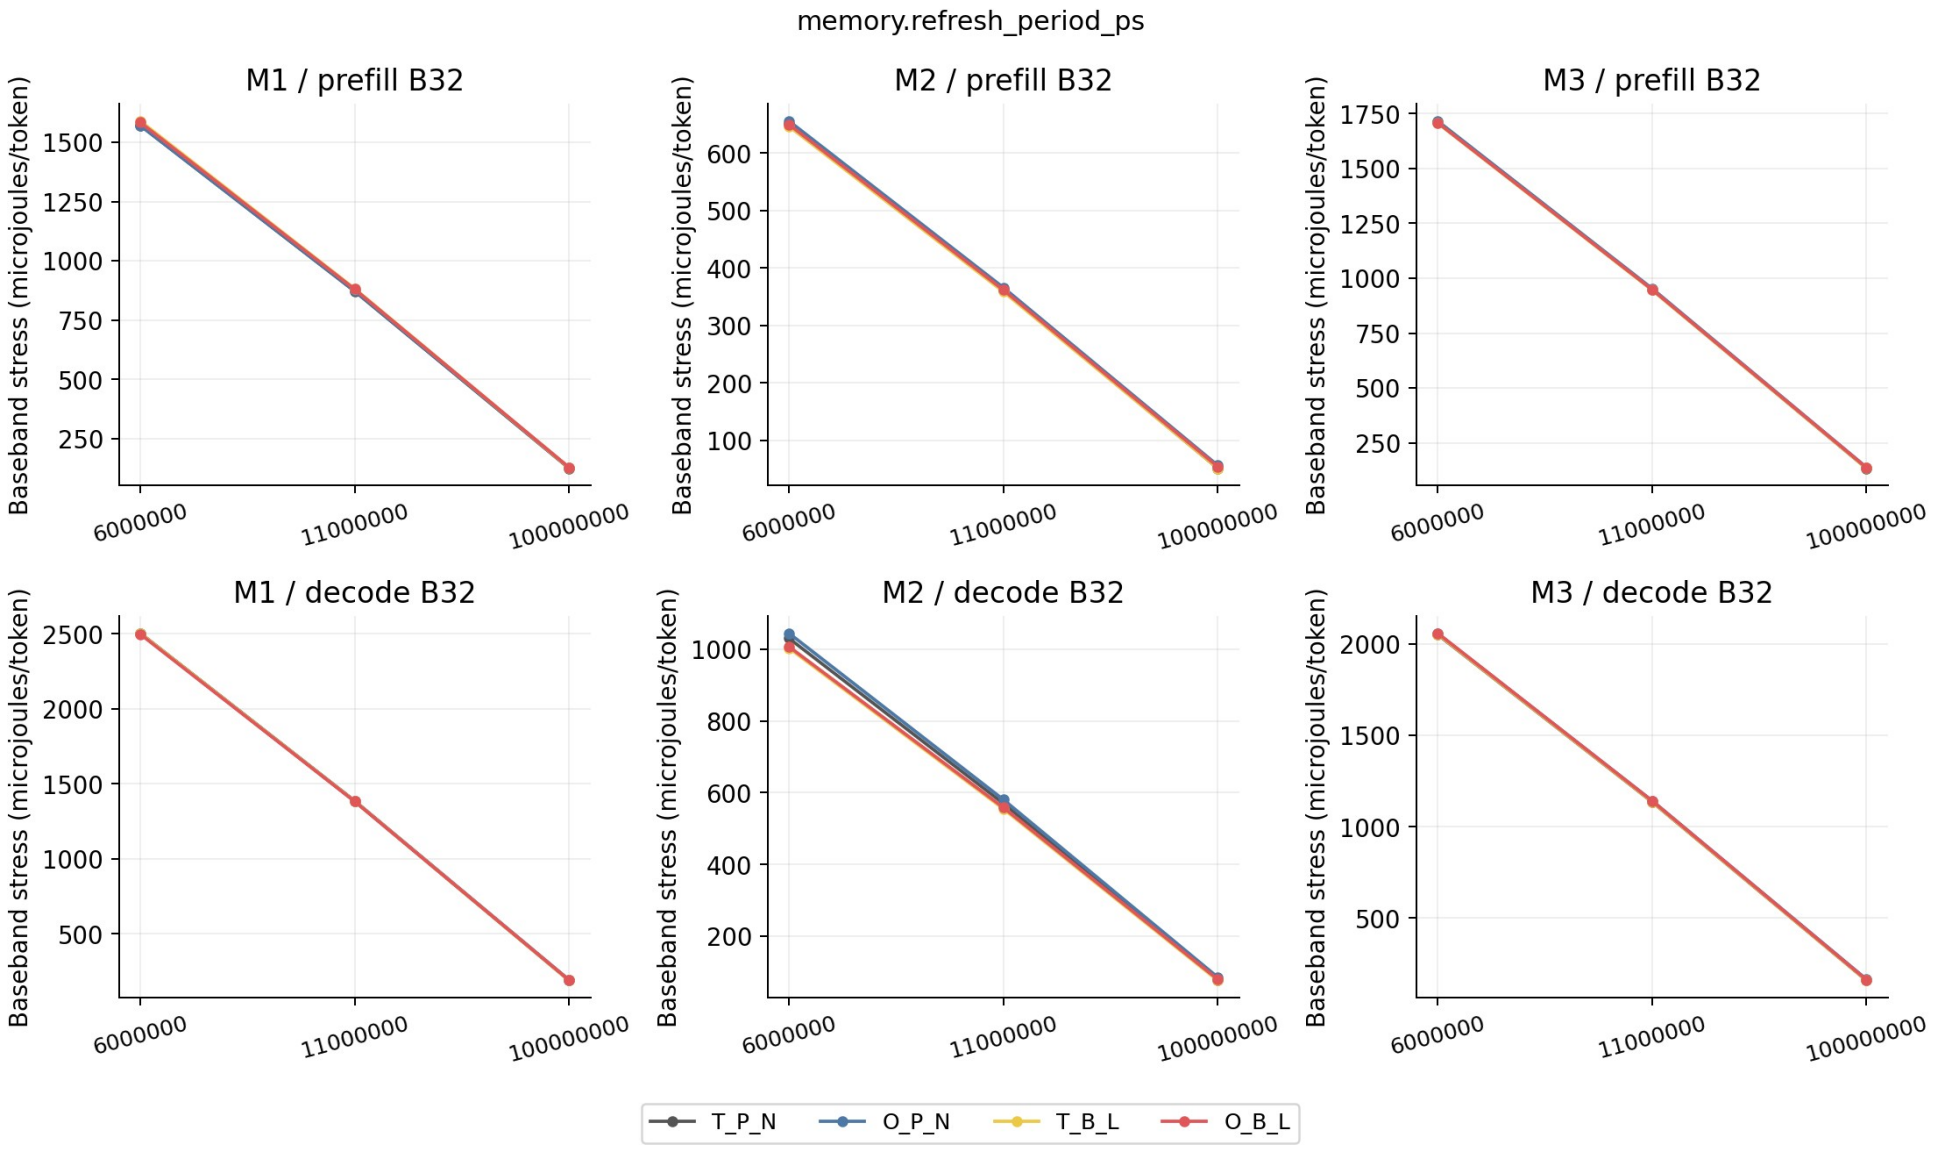
单因素敏感性：radio.rate_scale；指标：Mean request layer time (ms)；其余参数维持默认。



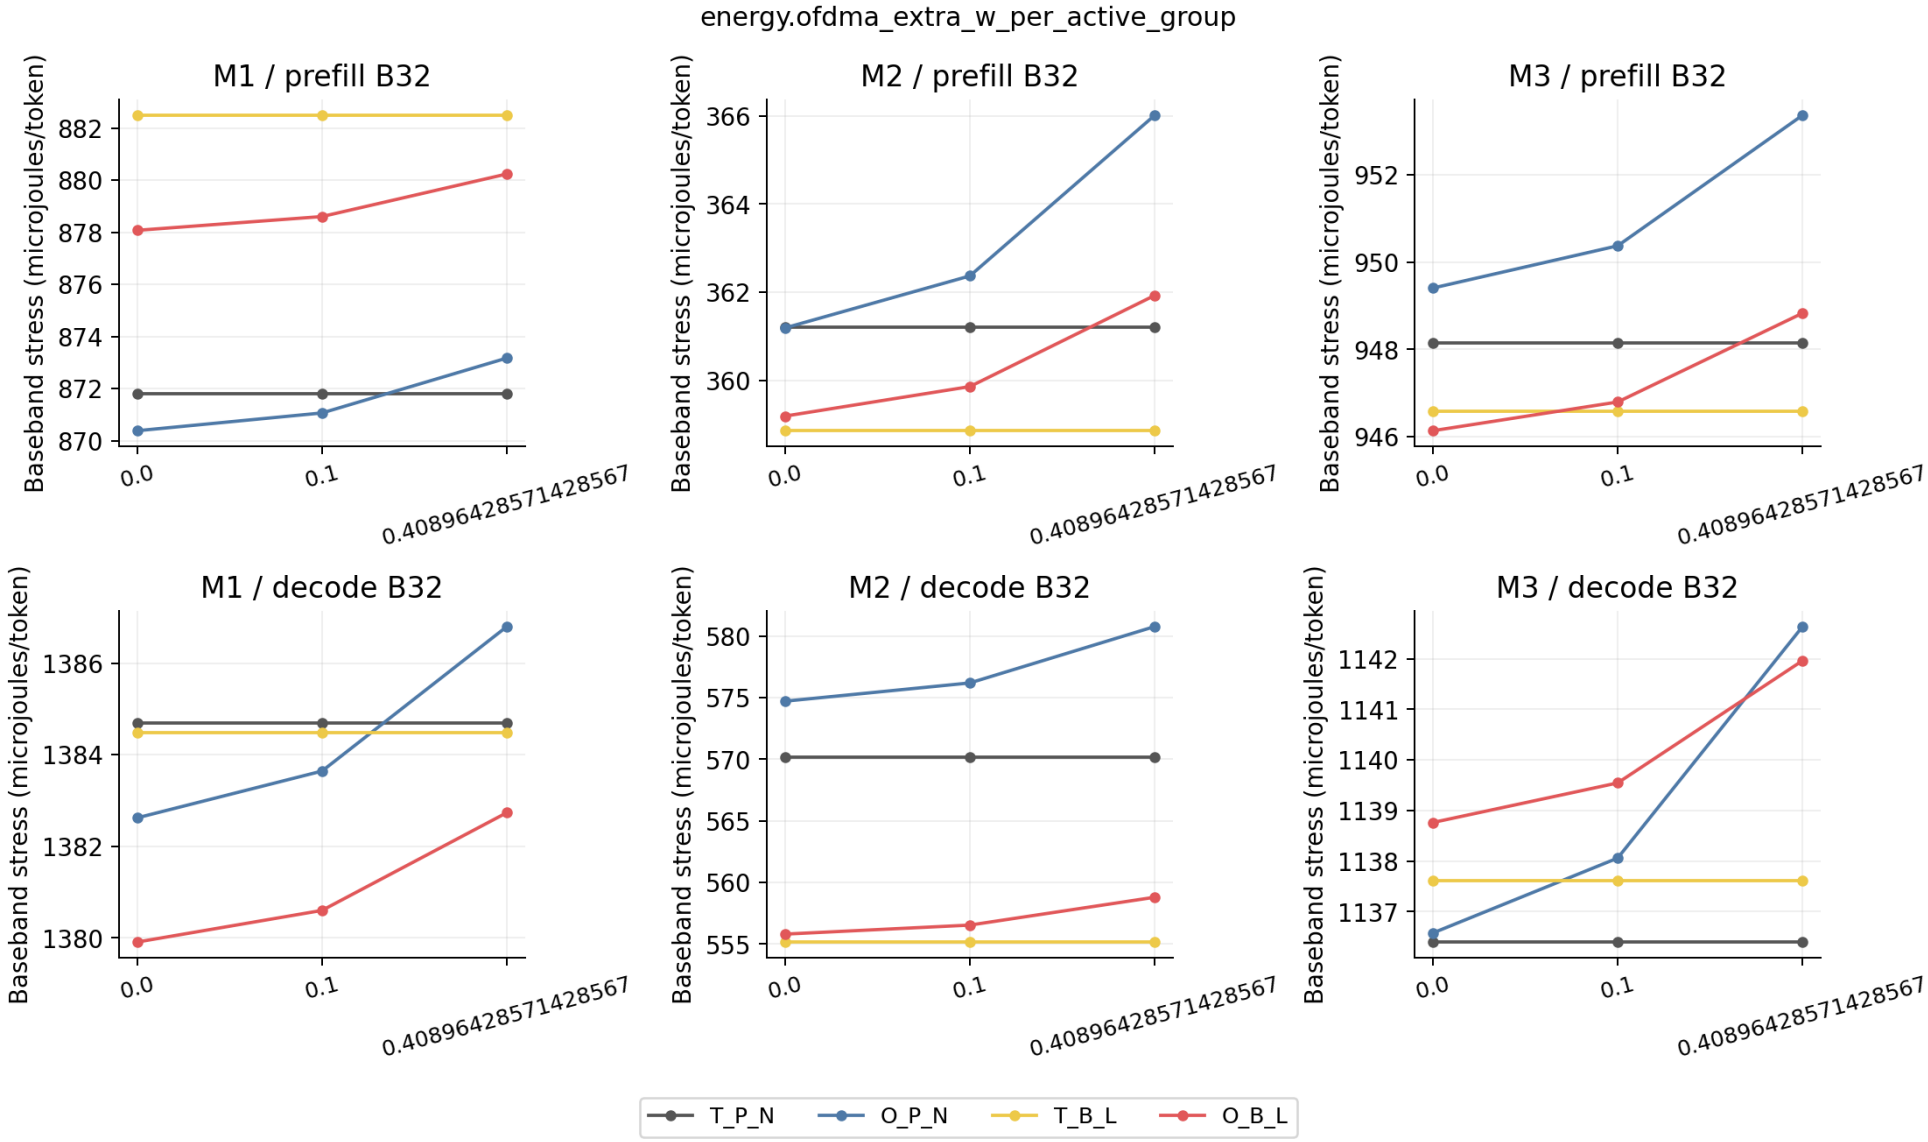
单因素敏感性：memory.bandwidth_scale；指标：Mean request layer time (ms)；其余参数维持默认。



单因素敏感性：workload.routing_profile；指标：Mean request layer time (ms)；其余参数维持默认。



单因素敏感性：memory.refresh_period_ps；指标：Baseband stress (microjoules/token)；其余参数维持默认。



单因素敏感性：energy.ofdma_extra_w_per_active_group；指标：Baseband stress (microjoules/token)；其余参数维持默认。

7. 结论

M1 decode B32：O_B_L 相对 T_P_N 的加速比为 1.0083，95%区间[1.0067, 1.0102]；前端 proxy 节能率 0.348%（95%区间[0.176%, 0.519%]），基带压力账本节能率 0.142%（95%区间[-0.031%, 0.314%]）。

M1 prefill B32：O_B_L 相对 T_P_N 的加速比为 0.9459，95%区间[0.9308, 0.9616]；前端 proxy 节能率-0.702%（95%区间[-1.161%, -0.197%]），基带压力账本节能率-0.965%（95%区间[-1.415%, -0.468%]）。

M2 decode B32：O_B_L 相对 T_P_N 的加速比为 1.0190，95%区间[1.0174, 1.0208]；前端 proxy 节能率 2.521%（95%区间[2.177%, 2.843%]），基带压力账本节能率 1.991%（95%区间[1.649%, 2.317%]）。

M2 prefill B32：O_B_L 相对 T_P_N 的加速比为 0.9617，95%区间[0.9492, 0.9746]；前端 proxy 节能率 0.623%（95%区间[0.010%, 1.161%]），基带压力账本节能率-0.199%（95%区间[-0.844%, 0.356%]）。

M3 decode B32：O_B_L 相对 T_P_N 的加速比为 1.0178，95%区间[1.0159, 1.0197]；前端 proxy 节能率-0.211%（95%区间[-0.500%, 0.132%]），基带压力账本节能率-0.490%（95%区间[-0.780%, -0.149%]）。

M3 prefill B32：O_B_L 相对 T_P_N 的加速比为 0.9133，95%区间[0.8921, 0.9351]；前端 proxy 节能率 0.226%（95%区间[-0.501%, 0.999%]），基带压力账本节能率-0.072%（95%区间[-0.805%, 0.715%]）。

加速比区间包含 1 时，尚未显示稳定的延迟优势；节能率区间包含 0 时，尚未显示稳定的能量优势。组合变化不能全部归功于 OFDMA，须结合第 6 节固定其它机制的条件比较。

M1 decode B32：O_P_N 相对强基线 TW_P_N 加速比 0.9977，区间完全低于 1。该比较保留实际控制成本并去除了固定帧空尾。

M1 decode B32：O_B_L 相对强基线 TW_B_L 加速比 1.0048，区间完全高于 1。该比较保留实际控制成本并去除了固定帧空尾。

M1 prefill B32：O_P_N 相对强基线 TW_P_N 加速比 1.0046，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

M1 prefill B32：O_B_L 相对强基线 TW_B_L 加速比 1.0010，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

M2 decode B32：O_P_N 相对强基线 TW_P_N 加速比 0.9784，区间完全低于 1。该比较保留实际控制成本并去除了固定帧空尾。

M2 decode B32：O_B_L 相对强基线 TW_B_L 加速比 0.9955，区间完全低于 1。该比较保留实际控制成本并去除了固定帧空尾。

M2 prefill B32：O_P_N 相对强基线 TW_P_N 加速比 1.0029，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

M2 prefill B32：O_B_L 相对强基线 TW_B_L 加速比 0.9964，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

M3 decode B32：O_P_N 相对强基线 TW_P_N 加速比 0.9925，区间完全低于 1。该比较保留实际控制成本并去除了固定帧空尾。

M3 decode B32：O_B_L 相对强基线 TW_B_L 加速比 0.9963，区间完全低于 1。该比较保留实际控制成本并去除了固定帧空尾。

M3 prefill B32：O_P_N 相对强基线 TW_P_N 加速比 1.0054，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

M3 prefill B32：O_B_L 相对强基线 TW_B_L 加速比 1.0015，区间包含 1。该比较保留实际控制成本并去除了固定帧空尾。

所有结果是单层、热态、真实文本长度与合成路由下的架构模型估计。16 节点覆盖、两介质隔离、在线均衡/OFDMA 基带、64MB eDRAM 外围及跨精度计算能耗仍含未实测外推；置信区间描述路由种子和请求变化，不覆盖硬件模型不确定性。

当前未满足的验收项为 FP8 小算例 NRMSE≤5%。本文保留失败结果和原门槛；可用于检查时序/资源/能耗模型和比较机制，但不能作为满足数值精度要求或真实目标芯片 PPA 的证据。

附录：复现与文件索引

安装：bash scripts/setup_env.sh。完整复现：python -m vdie_moe_sim.run_all --spec VDIE_MOE_SIM_SPEC.md --output results。已有同版本结果使用--resume；--require-numeric-gate 可要求在该数值验收失败时先停止时序实验。

token_metrics.parquet 是按时序配置分片的 Parquet 数据集，避免复制能量情景的同一 token 时间表；raw_runs.csv 中的 temporal_run_id 连接重算/等价记录。runs/<id>/ledger.parquet 保留事件计数，record.json 保存输入/引擎/文件哈希。

文件	内容
manifest.json / validation.json	完整计划、来源与依赖、完成状态、通过/失败检查
parameters.csv / config_resolved.yaml	参数含义与实际主配置；每条 overrides 在 manifest 中
traces/*.jsonl.gz / input_manifest.json	冻结路由和真实分词长度、revision、文件哈希
raw_runs.csv / aggregate.csv	全部记录及五种子汇总
token_metrics.parquet / cohort_metrics.parquet	token 细节及配对 cohort 单位
paired_effects.csv / factorial_interactions.csv / factorial_summary.csv	三机制配对效应与交互项；含共同配对 95%区间
resource_and_dependency_metrics.csv	计算/DMA 资源 busy-time、利用率与依赖路径分解
scheduler_metrics.csv	有效帧长、控制窗口/利用率、包粒度 grant 平均服务时长

文件	内容
energy_breakdown.csv / ofdma_power_threshold.csv	能耗分项与新增基带功耗盈亏阈值
figures/*.png / *.svg / *.csv	可导出图表及每图源数据

论文数据与条件采用上传规范中的来源标注；官方模型配置、数据集和 tokenizer 均冻结版本。P1 的 264Gb/s 为双通道合计；P2 为 FP16 SRAM-CIM 原型；P7 为小宏仿真；P8 为 DMT 接收器压力参照，均不伪装为目标 16-Die 芯片实测。

引用	URL
P1	https://doi.org/10.1109/JSSC.2026.3720291
P2	https://doi.org/10.1109/JSSC.2024.3402808
P3	https://arxiv.org/abs/2508.10925
P4	https://arxiv.org/abs/2505.09388
P5	https://ernie.baidu.com/blog/publication/ERNIE_Technical_Report.pdf
P6	https://arxiv.org/abs/2412.19437
P7	https://doi.org/10.3390/jlpea14010002
P8	https://doi.org/10.1109/JSSC.2025.3618188
P9	https://arxiv.org/abs/2504.05897
P10	https://arxiv.org/abs/2502.09007
C1	https://huggingface.co/openai/gpt-oss-20b/blob/main/config.json
C2	https://huggingface.co/Qwen/Qwen3-30B-A3B/blob/main/config.json
C3	https://huggingface.co/baidu/ERNIE-4.5-21B-A3B-PT/blob/main/config.json
C4	https://github.com/openai/gpt-oss/blob/main/gpt_oss/torch/model.py
C5	https://github.com/huggingface/transformers/blob/v4.55.4/src/transformers/models/ernie4_5_moe/modeling_ernie4_5_moe.py
D1	https://huggingface.co/datasets/MohamedRashad/ChatGPT-prompts